

Inventario Organizado de Variables

Proyecto: consumo de marihuana en Colombia

March 10, 2026

1 Objetivo de este archivo

Este documento organiza las variables que se van a usar en la primera etapa del proyecto. El orden de trabajo queda asi:

1. definir variables y construir una base unificada;
2. limpiar y recodificar;
3. estimar un modelo MCO como benchmark de propension;
4. estimar un modelo Probit para la misma variable dependiente.

La variable objetivo inicial sera la propension a consumir marihuana en los ultimos 12 meses.

2 Fuentes y llaves de union

Se identificaron tres fuentes principales:

Archivo	Contenido	Llaves
<code>base_consumo_drogas_colombianas.csv</code>	Variables privadas de consumo, gasto, precio, acceso y actitudes	<code>id_hogar</code> , <code>id_encuesta</code> , <code>id_persona</code> , <code>orden_persona</code>
<code>personas_processed.csv</code>	Sexo, edad y variables basicas de persona	<code>directorio</code> , <code>secuencia_encuesta</code> , <code>secuencia_p</code> , <code>orden</code>
<code>d2_capitulos.csv</code>	Escolaridad y otras características sociodemograficas	<code>directorio</code> , <code>secuencia_encuesta</code> , <code>secuencia_p</code> , <code>orden</code>

La verificacion de llaves muestra coincidencia completa entre la base de consumo y las bases `personas` y `d2` para las 3982 observaciones disponibles en la base de consumo.

3 Variables priorizadas para el modelo de propension

3.1 Variable dependiente

Variable limpia	Codigo origen	Definicion segun diccionario	Uso propuesto
consumo_12m	K_03	“¿Ha consumido marihuana en los ultimos 12 meses?” Dominio: 1 Si, 2 No, 9 No contesta.	Variable dependiente para MCO y Probit. Debe recodificarse a binaria.

3.2 Variables explicativas principales

Variable limpia	Codigo origen	Definicion segun diccionario	Rol en el modelo
precio_compra	K_09, K_09_VALOR	K_09: “¿Usted sabe cuanto cuesta un cigarrillo o porro de marihuana?”; K_09_VALOR: valor numerico.	Regresor de interes para escenarios de precio. Requiere limpieza fuerte.
sexo	sexo	Sexo. Dominio: 1 Hombre, 2 Mujer.	Control demografico.
edad	edad	“¿Cuantos anos cumplidos tiene la persona?” Dominio: 00 a 108.	Control demografico. Se recomienda incluir edad y edad al cuadrado.
d2_05	D2_05	Nivel educativo mas alto alcanzado. Dominio: 1 Ninguno, 2 Preescolar, 3 Basica primaria, 4 Basica secundaria, 5 Media, 6 Tecnica/tecnologica, 7 Universitaria, 8 Postgrado, 9 No sabe / No informa.	Control socioeconomico principal.
frecuencia_consumo	K_04	“En los ultimos 12 meses, ¿con que frecuencia ha consumido marihuana?” Dominio: 1 una sola vez, 2 algunas veces en 12 meses, 3 algunas veces mensualmente, 4 algunas veces semanalmente, 5 diariamente, 9 no contesta.	Variable de apoyo. No debe ir en la especificacion base si se interpreta como muy cercana al resultado.
facil_marihuana	G_06_A	Facilidad para conseguir marihuana. Dominio: 1 me seria facil, 2 me seria dificil, 3 no podria conseguir, 9 no sabe.	Proxy de acceso/oferta.
consumo_30d	K_05	“¿Ha consumido marihuana en los ultimos 30 dias?” Dominio: 1 Si, 2 No, 9 No contesta.	Variable auxiliar para validacion, no para la primera especificacion de propension anual.

Variable limpia	Codigo origen	Definicion segun diccionario	Rol en el modelo
consumo_vida	K_02	Momento de primera vez de consumo. Dominio: 1 en los ultimos 30 dias, 2 hace mas de 30 dias y menos de 12 meses, 3 hace mas de 12 meses, 9 no contesta.	Variable historica de apoyo; revisar interpretacion antes de usar.

3.3 Variables secundarias para una etapa posterior

Variable limpia	Codigo origen	Definicion segun diccionario	Comentario
cantidad_consumo	K_08	“En promedio, ¿cuantos cigarrillos de marihuana consume usted al mes?”	Util para un segundo modelo de intensidad, no para la primera etapa.
gasto_valor	K_07	“¿Cuanto gasto usted en marihuana durante los ultimos 30 dias?”	Alternativa para intensidad o gasto, no para la primera especificacion de propension.
gasto_descripcion	K_09_TEXTO	Valor en letras.	Puede servir para depurar precio_compra o gasto.

4 Disponibilidad de las variables en la base de consumo

La disponibilidad observada en la base de consumo actual es la siguiente:

Variable	No nulos	% faltantes	Comentario
consumo_12m	1719	56.8	La codificacion actual parece tener casos con 1 y muchos faltantes; debe validarse contra el cuestionario.
precio_compra	823	79.3	Muy incompleta para usarla en toda la muestra.
cantidad_consumo	1223	69.3	Reservar para segunda etapa.
gasto_valor	1014	74.5	Reservar para segunda etapa.
frecuencia_consumo	3982	0.0	Variable completa, pero cercana al comportamiento de consumo.
facil_marihuana	436	89.1	Cobertura muy baja; usar con cautela.

Adicionalmente, `precio_compra` no esta presente solo entre consumidores de 12 meses: hay 220 casos con precio no nulo entre observaciones hoy recodificables como no consumidoras en 12 meses y 603 casos con precio no nulo entre consumidoras de 12 meses. Esto sugiere revisar cuidadosamente la logica de saltos y las derivaciones de la base limpia.

5 Reglas de limpieza propuestas

1. Unir la base de consumo con `personas` y `d2` usando las llaves equivalentes.
2. Recodificar variables binarias del cuestionario respetando el diccionario:
 - 1 = Si
 - 2 = No
 - 9 = No contesta
3. Revisar si los faltantes en `consumo_12m` significan realmente 0 o si deben quedar como NA.
4. Tratar codigos especiales en precio y cantidad antes de estimar: por ejemplo 9, 98, 99 u otros valores de no respuesta si aparecen en la base derivada.
5. Crear una variable binaria de trabajo:

$$y_i = 1(\text{consumo_12m}_i = 1)$$

dejando como 0 los casos en que se confirme “No” y como NA los no contestados o ambiguos.

6. Para modelos con precio, considerar usar $\log(\text{precio_compra})$ luego de eliminar valores invalidos.
7. Para `d2_05`, agrupar categorias si la muestra por nivel educativo es pequena.

6 Hoja de ruta de modelado

6.1 Modelo 1: MCO como benchmark de propension

Primera especificacion recomendada:

$$y_i = \beta_0 + \beta_1 \log(\text{precio}_i) + \beta_2 \text{edad}_i + \beta_3 \text{edad}_i^2 + \beta_4 \text{sexo}_i + \beta_5 \text{educacion}_i + u_i$$

donde y_i es una variable binaria de consumo en ultimos 12 meses. Este modelo se interpreta como un *linear probability model* y se usa como benchmark simple.

6.2 Modelo 2: Probit de propension

Segunda especificacion recomendada:

$$Pr(y_i = 1 \mid X_i) = \Phi(\alpha_0 + \alpha_1 \log(\text{precio}_i) + \alpha_2 \text{edad}_i + \alpha_3 \text{edad}_i^2 + \alpha_4 \text{sexo}_i + \alpha_5 \text{educacion}_i)$$

Este sera el modelo econometrico principal para la primera etapa del proyecto.

6.3 Nota metodologica importante

Si `precio_compra` sigue siendo demasiado incompleta luego de limpiar, conviene trabajar con dos especificaciones:

1. una especificacion de muestra completa sin precio;
2. una especificacion reducida con precio para explorar sensibilidad o elasticidad.

Eso evita perder demasiada muestra desde el inicio.

7 Siguiente paso

Con este inventario, el siguiente paso ya no es discutir nombres de variables sino construir la base final de modelado:

1. merge de archivos;
2. recodificacion limpia de K_03, K_09_VALOR, sexo, edad y D2_05;
3. tabla descriptiva;
4. MCO benchmark;
5. Probit.