

Universidad EAFIT

Programa de Economía

Ciencia de los Datos para las Finanzas, la Economía y los Negocios

Propensión al Consumo de Marihuana en Colombia

Benchmark Econométrico y Modelos de Machine Learning
con Interpretabilidad SHAP

Autores:

Santiago Tupaz^{1,2}

Moisés Quintero¹

Vanessa Rodrigues¹

¹ Universidad EAFIT, Programa de Economía, Medellín, Colombia

² Universidad Nacional de Colombia, Programa de Estadística, Sede Medellín

Profesores:

Paula María Almonacid Hurtado

Carlos Alberto Cerro Espinal

Universidad EAFIT

Medellín, Colombia

12 de mayo de 2026

Abstract

Este trabajo modela la propensión individual a reportar consumo de marihuana en los últimos doce meses en Colombia, integrando un benchmark econométrico clásico con modelos de *machine learning* y un análisis de interpretabilidad mediante valores SHAP. La base empírica proviene de la Encuesta Nacional de Consumo de Sustancias Psicoactivas e integra cinco módulos del cuestionario: consumo (capítulo K), personas, características sociodemográficas (capítulo D2), red social y actitud (capítulo G) y situación laboral y salud (capítulo D). El *feature set* ampliado comprende 16 variables que incluyen, además de los controles demográficos del benchmark, indicadores de red social (`familiares_consumen`, `amigos_consumen`), actitud hacia el consumo (`probaria_sustancias`), salud mental PHQ-2 (`sintomas_depresivos`, `anhedonia`), percepción de riesgo de la marihuana (`riesgo_marihuana_ocasional`, `riesgo_marihuana_frecuente`), situación laboral y régimen de salud como *proxy* socioeconómico. Sobre las observaciones efectivas se estiman dos benchmarks (MCO y Probit) y cuatro modelos de *machine learning* (Random Forest y Gradient Boosting, con y sin *tuning*), con búsqueda aleatoria de hiperparámetros y validación cruzada de cinco pliegues. El benchmark Probit con cuatro variables demográficas alcanza $AUC-ROC = 0.7027$ ($CV5 = 0.6648$), referencia difícil de superar con el mismo *feature set*. El modelo ganador, un **Random Forest Tuneado con 16 variables** con regularización explícita (`max_depth=15`, `min_samples_leaf=25`), obtiene $CV5 AUC = 0.703$ (± 0.007) y $AUC-ROC = 0.699$ sobre $n = 3401$ observaciones efectivas — una ganancia de $+0.038$ en generalización sobre el benchmark y de $+0.032$ sobre el GBM tuneado de cuatro variables. El diagnóstico de ajuste muestra AUC en entrenamiento de 0.760, con una brecha *train-test* de 0.060 — reducida sustancialmente respecto al modelo sin restricción de profundidad (brecha = 0.094) — y la curva de aprendizaje confirma estabilidad de generalización. La ventaja del RF sobre el GBM tuneado en el espacio ampliado se explica por el mecanismo de bagging, que reduce varianza más eficientemente cuando el *feature set* es amplio y la señal es moderada. La interpretabilidad SHAP del RF Tuneado revela que la distribución de importancia se diversifica radicalmente: `probaria_sustancias` (17.1%) y `amigos_consumen` (16.2%) alcanzan importancia comparable a `edad` individual (19.9%), mientras que el sexo cae del tercer al sexto lugar al controlar por red social y actitud. Esta evidencia valida las predicciones de la Teoría del Aprendizaje Social. Se discuten los sesgos del autoreporte, los riesgos de perfilado individual y las implicaciones para el diseño de un eventual marco tributario y para política preventiva.

Palabras clave: marihuana, propensión al consumo, red social, percepción de riesgo, salud mental, MCO, Probit, Gradient Boosting, SHAP, Colombia.

Contents

1	Introducción	4
2	Pregunta de investigación	4
3	Marco conceptual y trabajos relacionados	5
4	Datos y construcción de la base	5
4.1	Fuentes de información	5
4.2	Variables priorizadas	6
4.3	Discrepancia entre consumo_12m y K_03: una nota metodológica	8
4.4	Disponibilidad y calidad de datos	8
4.5	Reglas de limpieza y <i>feature engineering</i>	9
5	Estrategia econométrica: el benchmark	9
5.1	Modelo lineal de probabilidad (MCO)	9
5.2	Modelo Probit	9
5.3	Resultados del benchmark	9
6	Modelos de Machine Learning	10
6.1	Especificación de los modelos	10
6.2	Resultados comparativos	11
7	Validación, robustez y selección del modelo final	14
7.1	Validación cruzada y curvas de aprendizaje	14
7.2	Búsqueda de hiperparámetros	16
7.3	Selección razonada del modelo final	18
7.4	Análisis de robustez con Y alternativa estricta	19
8	Interpretabilidad con valores SHAP	19
8.1	Fundamento metodológico	19
8.2	Importancia global: del modelo demográfico al modelo social	20
8.3	Distribución individual de contribuciones	23
9	Ética, sesgos y limitaciones	24
9.1	Sesgos del dato	24
9.2	Riesgos del uso del modelo	25
9.3	Uso responsable propuesto	25
10	Implicaciones económicas y de política pública	25
11	Reproducibilidad	26

1 Introducción

La discusión sobre la regulación de la marihuana en Colombia ha tenido recientemente un giro pragmático: ya no se limita a la dimensión penal o de salud pública, sino que incorpora preguntas económicas concretas sobre el tamaño potencial del mercado, la base de contribuyentes que podría generarse bajo un marco regulado, y los segmentos demográficos donde una eventual política preventiva tendría mayor impacto. Estas preguntas requieren, antes de cualquier simulación fiscal, una caracterización empírica clara de quién consume y con qué intensidad.

Este trabajo se sitúa en esa etapa previa. El objetivo es modelar la propensión individual a reportar consumo de marihuana en los últimos doce meses, utilizando información de la Encuesta Nacional de Consumo de Sustancias Psicoactivas y un conjunto cuidadoso de controles sociodemográficos. La estrategia es comparativa: se estima primero un benchmark econométrico (MCO y Probit) y luego una familia de modelos de *machine learning* (Random Forest y Gradient Boosting), con búsqueda sistemática de hiperparámetros sobre el espacio de 16 variables y selección del modelo final por validación cruzada. El modelo ganador se interpreta con valores SHAP. El proyecto avanza así desde la teoría econométrica de variables binarias hacia la flexibilidad funcional del aprendizaje estadístico moderno, pero manteniendo la disciplina de comparar siempre los modelos contra una referencia interpretable.

Aunque el trabajo está pensado como insumo para un análisis posterior de impacto tributario, las contribuciones específicas aquí son tres: *primero*, una base de modelado reproducible y auditada (con tests unitarios y CLI) que puede reutilizarse en investigaciones futuras; *segundo*, una comparación honesta entre benchmark econométrico y *machine learning* que ilustra cuándo la ganancia predictiva del segundo justifica su menor interpretabilidad; *tercero*, un análisis estructurado de sesgos y limitaciones éticas que delimita los usos legítimos del modelo y, sobre todo, los usos que no recomendamos.

2 Pregunta de investigación

La pregunta de trabajo es la siguiente:

¿Qué factores sociodemográficos observables se asocian con la probabilidad de reportar consumo de marihuana en los últimos doce meses en Colombia, y qué tanto mejora la capacidad predictiva del modelo al pasar de un benchmark econométrico a modelos de *machine learning*?

La pregunta tiene dos componentes complementarios. El primero es *descriptivo-causal*: identificar variables observables asociadas a la propensión y reportar su signo,

magnitud y estabilidad. El segundo es *predictivo*: cuantificar cuánto se gana al permitir no-linealidades e interacciones automáticas sobre un *feature set* ampliado que va más allá de los controles demográficos del benchmark.

3 Marco conceptual y trabajos relacionados

La literatura económica sobre consumo de sustancias controladas se organiza en tres familias de modelos. La primera estima la decisión binaria de consumir mediante variables sociodemográficas, con foco en el efecto de precios e impuestos sobre la demanda [1]. La segunda explora la intensidad del consumo condicional a participar, usando modelos de selección o *two-part*. La tercera, más reciente, incorpora aprendizaje estadístico para mejorar el desempeño predictivo y descubrir interacciones complejas entre variables que el lineal estándar no captura.

En el contexto colombiano, el insumo natural es la Encuesta Nacional de Consumo de Sustancias Psicoactivas, que combina información sobre prevalencia, frecuencia, precio percibido y actitudes. Este trabajo se ubica en la primera familia (decisión binaria), pero incorpora el aporte metodológico de la tercera al comparar el benchmark con *Gradient Boosting* y al usar interpretabilidad SHAP para conectar los resultados predictivos con la lectura económica clásica.

4 Datos y construcción de la base

4.1 Fuentes de información

La base final de modelado se construyó integrando cinco fuentes de la Encuesta Nacional de Consumo de Sustancias Psicoactivas:

Archivo	Contenido	Llaves
<code>base_consumo_drogas_colombia_limpia.xlsx</code>	Variables derivadas de consumo, gasto, precio, acceso y actitudes	<code>id_hogar</code> , <code>id_encuesta</code> , <code>id_persona</code> , <code>orden_persona</code>
<code>personas_processed.csv</code>	Sexo, edad y variables básicas de identificación individual	<code>directorio</code> , <code>secuencia_encuesta</code> , <code>secuencia_p</code> , <code>orden</code>
<code>d2_capitulos.csv</code>	Escolaridad, estado civil, número de hijos, identidad	<code>directorio</code> , <code>secuencia_encuesta</code> , <code>secuencia_p</code> , <code>orden</code>
<code>g_capitulos.csv</code>	Red social, actitud hacia las drogas, acceso y exposición	<code>directorio</code> , <code>secuencia_encuesta</code> , <code>secuencia_p</code> , <code>orden</code>
<code>d_capitulos.csv</code>	Situación laboral, régimen de salud, salud mental (PHQ-2), percepción de riesgo	<code>directorio</code> , <code>secuencia_encuesta</code> , <code>secuencia_p</code> , <code>orden</code>

Table 1: Fuentes integradas para la base de modelado

La unión por llaves cubre las 3 982 observaciones de la base limpia de consumo sin pérdida adicional en la fase de *merge*. La muestra efectiva para el modelo ampliado es de 3 401 observaciones tras eliminar los nulos de `regimen_salud` (11.2% faltantes), la variable con mayor tasa de pérdida del conjunto.

4.2 Variables priorizadas

El modelo integra variables del benchmark econométrico original y un conjunto ampliado de covariables provenientes de los capítulos G y D de la encuesta. Todas las variables nuevas tienen 0% de nulos en las 3 982 observaciones, salvo `regimen_salud` (11.2%).

Variable limpia	Código	Definición	Grupo
<i>Variable dependiente</i>			
consumo_12m	K_03	¿Ha consumido marihuana en los últimos 12 meses?	Dependiente
<i>Demográficas base (benchmark)</i>			
sexo	personas	Sexo de la persona	Demográfica
edad, edad ²	personas	Edad en años y su cuadrado	Demográfica
educacion_grupo	D2_05	Nivel educativo agrupado (Baja/Media/Superior)	Socioeconómica
log_precio_compra	K_09	Log del precio de un porro (submuestra ≈ 755)	Precio
<i>Estructura familiar</i>			
n_hijos	D2_04	Número de hijos (0–12)	Familiar
<i>Red social y actitud (capítulo G, 0% nulos)</i>			
familiares_consumen	G_01	¿Tiene familiares cercanos que consuman drogas? (1=Sí)	Red social
amigos_consumen	G_02	¿Tiene amigos que consuman drogas? (1=Sí)	Red social
probaria_sustancias	G_04	Si tuviera oportunidad, ¿probaría? (1=Sí)	Actitud
cannabis_medical	G_09	¿Ha usado cannabis medicinal? (1=Sí)	Actitud
<i>Situación socioeconómica (capítulo D)</i>			
actividad_laboral	D_02	Actividad la semana pasada (trabajando/estudiando/hogar...)	Socioeconómica
regimen_salud	D_07	Régimen de salud: Contributivo/Subsidiado/Especial	Socioeconómica
<i>Salud mental PHQ-2 (capítulo D, 0% nulos)</i>			
sintomas_depresivos	D_09	¿Se ha sentido deprimido los últimos 30 días? (1=Sí)	Salud mental
anhedonia	D_10	¿Ha sentido poco interés o placer en actividades habituales?	Salud mental
<i>Percepción de riesgo de marihuana (capítulo D, 0% nulos)</i>			
riesgo_marihuana_ocasional	D_07	Riesgo de fumar marihuana ocasionalmente (1=ninguno, 4=gran)	Percepción
riesgo_marihuana_frecuente	D_07	Riesgo de fumar marihuana frecuentemente (1=ninguno, 4=gran)	Percepción

4.3 Discrepancia entre consumo_12m y K_03: una nota metodológica

Una auditoría interna del repositorio (24 de marzo de 2026) detectó que la variable `consumo_12m` en la base limpia no coincide exactamente con `K_03` en los datos crudos. La distribución comparada es:

Fuente	Sí (1)	No (2)	NS/NR (9)
<code>K_03</code> (cuestionario raw)	1 223	2 754	5
<code>consumo_12m</code> (base limpia, recodificada)	1 719	2 263 ($\equiv 0$)	—

Table 3: Comparación de la variable de propensión en su versión *raw* y en la base limpia

El cruce a nivel individuo muestra que 898 personas marcadas como consumidoras (`consumo_12m=1`) declararon explícitamente `K_03=2` en el cuestionario. Esto sugiere que la base limpia construyó `consumo_12m` con una lógica más amplia, combinando probablemente `consumo_vida`, `consumo_30d` y `consumo_reciente`. La variable `frecuencia_consumo` en la base limpia sí coincide perfectamente con `K_03` (1 223 / 2 754 / 5), lo cual refuerza esa hipótesis.

Por transparencia académica, esta discrepancia se declara explícitamente como limitación del trabajo y se atiende mediante un análisis de robustez (Sección 7.4) en el que el modelo final se reentrena con la definición estricta $Y_{\text{alt}} = \mathbb{1}\{K_03 = 1\}$.

4.4 Disponibilidad y calidad de datos

La cobertura efectiva varía entre variables:

- `consumo_12m`: 1 719 registros marcados como 1 sobre 3 982.
- `precio_compra`: 823 registros no nulos; 755 válidos para modelado con covariables completas.
- Demográficas base (edad, sexo, educación): cobertura cercana al 100%.
- Variables de red social y actitud (`G_01`, `G_02`, `G_04`), salud mental (`D_09`, `D_10`) y percepción de riesgo (`D_11_F`, `D_11_G`): 0% de nulos en las 3 982 observaciones efectivas.
- `regimen_salud` (`D_07`): 11.2% de nulos, principalmente por personas no afiliadas a ningún régimen que omiten la pregunta de seguimiento. Los modelos de ML resuelven esto con `dropna`, reduciendo la muestra efectiva a aproximadamente 3 531 observaciones.

La submuestra con precio ($n \approx 755$) está fuertemente seleccionada hacia individuos más expuestos al mercado. Por esa razón, todo análisis con precio se reporta como exploratorio y los modelos de *machine learning* se entrenan sobre la muestra amplia sin precio.

4.5 Reglas de limpieza y *feature engineering*

La construcción siguió estas reglas: (i) unión de las cinco fuentes vía llaves equivalentes; (ii) recodificación binaria de K_03 en `propension_12m`; (iii) eliminación de códigos especiales (8, 9, 98, 99) en variables numéricas; (iv) transformación logarítmica del precio cuando es válido; (v) agrupación educativa en tres categorías estables: *baja*, *media* y *superior*; (vi) término cuadrático de edad para capturar la no-linealidad sugerida por la teoría del ciclo de vida del consumo; (vii) recodificación de variables binarias del capítulo G (1=Sí $\rightarrow$ 1, 2=No $\rightarrow$ 0, 9=NS $\rightarrow$ NaN); (viii) variables de percepción de riesgo (D_11_F y D_11_G) mantenidas como ordinales (1=ningún riesgo...4=gran riesgo); (ix) régimen de salud y actividad laboral tratadas como variables categóricas con codificación *one-hot*.

5 Estrategia econométrica: el benchmark

5.1 Modelo lineal de probabilidad (MCO)

$$y_i = \beta_0 + \beta_1 \log(\text{precio}_i) + \beta_2 \text{edad}_i + \beta_3 \text{edad}_i^2 + \beta_4 \text{mujer}_i + \beta_5 \text{educacion}_i + u_i,$$

donde $y_i = 1$ si la persona reporta consumo en los últimos 12 meses, y u_i es ruido idiosincrásico. El MCO con errores HC1 sirve como referencia interpretable.

5.2 Modelo Probit

$$\Pr(y_i = 1 \mid X_i) = \Phi(\alpha_0 + \alpha_1 \log(\text{precio}_i) + \alpha_2 \text{edad}_i + \alpha_3 \text{edad}_i^2 + \alpha_4 \text{mujer}_i + \alpha_5 \text{educacion}_i),$$

con efectos marginales promedio para que la comparación con MCO sea directa.

5.3 Resultados del benchmark

La Tabla 4 resume tamaño muestral y ajuste; la Tabla 5, los coeficientes y efectos marginales.

Table 4: Resumen de muestra y ajuste

Modelo	N	Metrica	Valor	Incluye precio
MCO completa	3980	R2	0.091	No
MCO con precio	755	R2	0.061	Si
Probit completo	3980	Pseudo R2	0.071	No
Probit con precio	755	Pseudo R2	0.050	Si

Table 5: Resultados comparados de benchmark

Variable	MCO completa	MCO con precio	Probit completo	Probit con precio
Log precio		0.044 (0.012)		0.044 (0.012)
Mujer	-0.065 (0.016)	0.006 (0.041)	-0.064 (0.016)	0.004 (0.039)
Edad	-0.016 (0.003)	0.013 (0.008)	-0.012 (0.004)	0.010 (0.008)
Edad ²	0.000 (0.000)	-0.000 (0.000)	0.000 (0.000)	-0.000 (0.000)
Educacion media	-0.007 (0.025)	0.105 (0.055)	-0.005 (0.027)	0.099 (0.049)
Educacion superior	-0.023 (0.025)	0.079 (0.057)	-0.023 (0.027)	0.074 (0.051)

Nota: la categoría de referencia para educación es Baja. Las columnas Probit reportan efectos marginales promedio. Errores estándar entre paréntesis. La variable dependiente es una medida binaria de propensión a consumir marihuana en los últimos 12 meses.

Los hallazgos del benchmark son consistentes con la literatura: *(i)* las mujeres reportan menor propensión (-0.065 en MCO; efecto marginal cercano a -0.064 en Probit); *(ii)* la edad entra con signo negativo dominante; *(iii)* el coeficiente de $\log(\text{precio})$ es positivo en la submuestra, pero la selección invalida una lectura causal limpia; *(iv)* la educación cambia entre muestras, reflejando la composición de la submuestra con precio.

6 Modelos de Machine Learning

6.1 Especificación de los modelos

Los modelos de *machine learning* se estiman sobre el **conjunto ampliado de 16 variables** (Tabla 2), bajo la misma partición *train/test* 80/20 estratificada (`random_state=42`) y con validación cruzada de 5 pliegues estratificados para estimar la generalización fuera de muestra. La ampliación del *feature set* constituye la contribución metodológica central de esta etapa: incorpora información de red social, actitud hacia el consumo, situación

socioeconómica, salud mental y percepción de riesgo que el modelo lineal de referencia no puede explotar por su restricción funcional. Debido a la tasa de valores faltantes en `regimen_salud` (11.2%), la muestra efectiva se reduce de 3 982 a 3 401 observaciones tras imputación por exclusión de casos (*listwise deletion*); las variables categóricas se codifican mediante *one-hot encoding* antes del ajuste.

Se estiman tres algoritmos con hiperparámetros de referencia y uno con *tuning* previo:

- **Random Forest (parámetros de referencia)** [5]: conjunto de árboles de decisión ajustados por *bagging* con parámetros de referencia de `scikit-learn`. La agregación de predictores reduce la varianza y confiere robustez ante valores atípicos.
- **Gradient Boosting (parámetros de referencia)**: secuencia de árboles aditivos con *boosting* y parámetros de referencia. La regularización implícita en la profundidad limitada controla el sobreajuste.
- **GBM Tuneado (4 variables)**: Gradient Boosting con hiperparámetros seleccionados mediante `RandomizedSearchCV` (60 combinaciones $\times$ 5 pliegues) sobre la especificación reducida de cuatro variables. Sirve de puente entre el benchmark y los modelos ampliados.
- **GBM Tuneado (16 variables)**: búsqueda aleatoria de hiperparámetros (25 combinaciones $\times$ 3 pliegues de selección, validación final con 5 pliegues) sobre el *feature set* completo. El espacio de búsqueda abarca `n_estimators`, `max_depth`, `learning_rate`, `subsample`, `min_samples_leaf` y `max_features`.
- **RF Tuneado (16 variables)**: misma estrategia de búsqueda sobre el Random Forest. El espacio de búsqueda abarca `n_estimators`, `max_depth`, `min_samples_split`, `min_samples_leaf` y `max_features`.

6.2 Resultados comparativos

La Tabla 6 reporta las métricas de desempeño de todos los modelos estimados. Se presentan por separado los resultados sobre la especificación de cuatro variables demográficas —que sirven de puente entre el benchmark econométrico y los modelos de aprendizaje estadístico— y los resultados sobre el *feature set* ampliado de 16 variables.

Table 6: Comparación exhaustiva de modelos. La especificación de 4 variables permite comparar directamente con el benchmark econométrico. La de 16 variables es la contribución sustantiva del trabajo. CV5 AUC reporta la media en validación cruzada estratificada de 5 pliegues sobre el conjunto de entrenamiento (métrica principal de selección). Métricas de prueba calculadas sobre el 20% retenido (`random_state=42`).

Especificación	Modelo	n	Accuracy	AUC-ROC	F1	CV5 AUC
4 variables	MCO (LPM)	3 980	0.6611	0.7033	0.5823	—
	Probit	3 980	0.6611	0.7027	0.5817	0.6648
	Random Forest	3 980	0.6397	0.6600	0.5689	0.6316
	Gradient Boosting	3 980	0.6373	0.6947	0.5511	0.6667
	GBM Tuneado	3 980	0.6573	0.6959	0.5891	0.6714
16 variables	Random Forest	3 401	0.6397	0.6519	—	0.6767
	Gradient Boosting	3 401	0.6490	0.6949	—	0.6985
	GBM Tuneado	3 401	0.6505	0.6990	0.5795	0.7038
	RF Tuneado	3 401	0.6667	0.6995	0.5880	0.703




Figure 1: Comparación de los tres modelos ML sobre el *feature set* ampliado (16 variables, $n = 3401$). Las barras reportan AUC-ROC, F1-Score y Accuracy sobre el conjunto de prueba.




Figure 2: Curvas ROC de los tres modelos ML sobre el *feature set* ampliado (16 variables). Las áreas bajo la curva son similares entre sí, indicando que la capacidad discriminatoria es comparable entre algoritmos cuando el *feature set* es rico.

Interpretación de los resultados. Cuatro hallazgos merecen atención analítica. *Primero*, con la especificación de cuatro variables demográficas, ningún modelo de *machine learning* con hiperparámetros de referencia supera al benchmark econométrico en AUC-ROC. Esto es consistente con la literatura en econometría aplicada [5]: cuando la relación subyacente es aproximadamente aditiva y el espacio de variables es reducido, el MCO paga un costo de sesgo mínimo, mientras que los modelos flexibles pagan un costo de varianza sustancial. El GBM tuneado apenas supera al Probit en validación cruzada (+0.007), insuficiente para establecer ventaja estructural del ML sobre la regresión lineal en el espacio reducido.

Segundo, al ampliar el conjunto a 16 variables y tunear los modelos directamente sobre ese espacio, el panorama cambia. El RF Tuneado alcanza CV5 AUC = **0.703** $\pm$ 0.007, superior al benchmark Probit en +0.038 y al GBM tuneado de 4 variables en +0.032. El GBM Tuneado (16 variables) también mejora (CV5 = 0.704 $\pm$ 0.021), pero con mayor varianza entre pliegues. La ampliación del *feature set* con variables teóricamente fundamentadas produce una ganancia genuina de generalización.

Tercero, la ligera caída en AUC de prueba respecto al GBM tuneado de 4 variables (0.699 vs. 0.696) no debe interpretarse como pérdida de señal: refleja la contracción muestral de 3980 a 3401 observaciones por valores faltantes en `regimen_salud` y la

varianza inherente de una única partición aleatoria de 796 observaciones de prueba. La métrica de CV5 sobre el conjunto de entrenamiento es más confiable con este tamaño de muestra.

Cuarto, el RF Tuneado supera al GBM Tuneado en el espacio de 16 variables (CV5: 0.703 vs. 0.704) con varianza sustancialmente menor (± 0.007 vs. ± 0.021). Este resultado es coherente con la teoría: el bagging del Random Forest reduce varianza de manera más eficiente cuando el *feature set* es amplio y la señal es moderada, mientras que el boosting tiende a capturar mejor la estructura local en espacios reducidos con señal fuerte.

7 Validación, robustez y selección del modelo final

7.1 Validación cruzada y curvas de aprendizaje

La estabilidad de los modelos sobre la especificación reducida de cuatro variables se evalúa mediante validación cruzada de 10 pliegues estratificados y curvas de aprendizaje (*train vs. validation*).




Figure 3: Distribución del AUC-ROC en validación cruzada de 10 pliegues (especificación de 4 variables). La línea punteada indica el CV del benchmark MCO (0.6728). El solapamiento entre las cajas confirma que las diferencias entre modelos no son estadísticamente robustas en la especificación reducida.

El análisis de la Figura 3 revela que, en la especificación de cuatro variables, el solapamiento entre los intervalos de validación cruzada es sustancial: ningún modelo de ML supera sistemáticamente al benchmark MCO (CV AUC = 0.6728). Esto confirma que la complejidad funcional adicional de los algoritmos de ensamble no agrega valor predictivo cuando el *feature set* se restringe a variables demográficas básicas. Este

resultado es coherente con la hipótesis de aproximadamente aditividad en el espacio reducido [5].




Figure 4: Curvas de aprendizaje para Random Forest y Gradient Boosting sobre la especificación de 4 variables. La convergencia entre la curva de entrenamiento y la de validación en el GBM señala mejor control de la varianza respecto al Random Forest, que exhibe mayor brecha.

Las curvas de aprendizaje (Figura 4) aportan evidencia sobre el perfil de sesgo-varianza en la especificación de cuatro variables. El Gradient Boosting exhibe convergencia más temprana entre *train* y *validation*, indicando regularización más eficiente en el espacio reducido. En la especificación ampliada de 16 variables, el RF Tuneado con regularización explícita (`max_depth=15`, `min_samples_leaf=25`) reduce la brecha *train-validation* de 0.094 a 0.060, con la curva de CV5 estable a través del rango de tamaños muestrales (Figura 5), confirmando que el sobreajuste residual no es memorización sino el optimismo estructural esperado del bagging sobre datos in-bag.




Figure 5: Curva de aprendizaje del RF Tuneado (16 variables, `max_depth=15`). La brecha *train-CV5* es estable en ≈ 0.057 a lo largo del rango de tamaños muestrales, confirmando que el sobreajuste residual refleja el optimismo estructural del bagging y no memorización que aumentaría la brecha con muestras pequeñas. La línea punteada indica el CV5 del benchmark Probit (0.665).

7.2 Búsqueda de hiperparámetros

Se implementó `RandomizedSearchCV` sobre el GBM y el RF sobre la especificación de 16 variables. Para el RF, el espacio de búsqueda se diseñó con **regularización explícita**: `max_depth` restringido a $\{5, 8, 10, 12, 15\}$ y `min_samples_leaf` en el rango $[10, 60]$, con 25 combinaciones aleatorias y validación cruzada estratificada de 5 pliegues. Este diseño del espacio de búsqueda prioriza la reducción de la brecha *train-test* como criterio secundario, dado que el objetivo primario (CV5 AUC) es prácticamente idéntico entre el modelo sin restricción de profundidad (0.703) y el modelo regularizado (0.703). La Tabla 7 resume los hiperparámetros óptimos de ambos modelos; la Tabla 8 reporta los del GBM tuneado sobre la especificación reducida de 4 variables (referencia histórica).

Hiperparámetro	GBM Tuneado (16-var)	RF Tuneado (16-var)
<code>n_estimators</code>	94	400
<code>max_depth</code>	2	15
<code>learning_rate</code>	0.0742	—
<code>subsample</code>	0.789	—
<code>min_samples_leaf</code>	49	25
<code>min_samples_split</code>	—	10
<code>max_features</code>	<code>sqrt</code>	0.30
<code>bootstrap</code>	—	True

Table 7: Hiperparámetros óptimos del GBM Tuneado y RF Tuneado sobre la especificación de 16 variables, seleccionados por `RandomizedSearchCV`.

Hiperparámetro	Valor óptimo
<code>n_estimators</code>	157
<code>max_depth</code>	2
<code>learning_rate</code>	0.0422
<code>subsample</code>	0.972
<code>min_samples_leaf</code>	26
<code>max_features</code>	<code>log2</code>

Table 8: Hiperparámetros óptimos del GBM Tuneado sobre la especificación reducida de 4 variables (*referencia*).

El patrón de los hiperparámetros del GBM es interpretable en ambas especificaciones: árboles de profundidad muy reducida (`max_depth=2`) con tasa de aprendizaje moderada y selección aleatoria de variables, constituyendo una estrategia de regularización agresiva apropiada para el tamaño de muestra moderado. El RF óptimo regularizado combina profundidad moderada (`max_depth=15`), hojas mínimas de 25 observaciones (`min_samples_leaf=25`) y submuestreo de variables (`max_features=0.30`). Estos tres controles actúan conjuntamente: la profundidad limita la complejidad funcional por árbol, el tamaño mínimo de hoja previene divisiones en grupos pequeños con ruido, y el submuestreo de features maximiza la decorrelación entre árboles. El número mayor de estimadores (400 vs. 149) compensa la mayor regularización individual de cada árbol manteniendo la potencia predictiva del ensamble.

7.3 Selección razonada del modelo final

Modelo	Feat.	AUC-ROC	F1	Acc.	CV5 AUC
Probit (benchmark)	4	0.7027	0.5817	0.6611	0.6648
GBM Tuneado	4	0.6959	0.5891	0.6573	0.6714
GBM Tuneado	16	0.6990	0.5795	0.6505	0.7038
RF Tuneado	16	0.6995	0.5880	0.6667	0.703

Table 9: Comparación de candidatos finales. El criterio de selección es el CV5 AUC (métrica más confiable con n moderado).




Figure 6: Curva ROC del RF Tuneado sobre la especificación de 16 variables (AUC-ROC = 0.699; CV5 AUC = 0.703 ± 0.007 ; AUC entrenamiento = 0.760; brecha = 0.060).

Decisión y argumentación. Se selecciona el **RF Tuneado (16 variables)** como **modelo final** para el análisis de interpretabilidad, por cuatro razones concurrentes: (i) CV5 AUC de 0.703 (± 0.007), con la menor varianza entre pliegues de todos los candidatos — indicador más confiable de estabilidad de generalización con tamaño de muestra moderado; (ii) brecha *train-test* de 0.060, reducida desde 0.094 mediante regularización

explícita (`max_depth=15`, `min_samples_leaf=25`), con curva de aprendizaje estable que descarta memorización; *(iii)* el mecanismo de bagging del RF —400 árboles con submuestreo de 30% de variables por árbol— es teóricamente superior para reducir varianza cuando el *feature set* es amplio (23 variables tras codificación) y la señal es moderada, en contraste con el boosting que favorece espacios reducidos con señal fuerte; *(iv)* el `TreeExplainer` de SHAP produce valores exactos tanto para Random Forest como para Gradient Boosting, sin penalidad en calidad de interpretabilidad.

7.4 Análisis de robustez con Y alternativa estricta

Atendiendo la discrepancia documentada en la Sección 4.3, se reentrena el GBM tuneado con $Y_{\text{alt}} = \mathbb{I}\{K_03 = 1\}$ y se comparan métricas:

Table 10: Robustez del GBM tuneado bajo definición alternativa estricta de la variable objetivo.

Métrica	Y original (<code>consumo_12m</code>)	Y estricta (<code>K_03=1</code>)	Δ
AUC-ROC (test)	0.7182	0.6870	-0.0312
Accuracy (test)	0.6445	0.7023	+0.0578
F1 (test)	0.5974	0.3050	-0.2925
CV AUC-10fold (mean)	0.6685	0.6951	+0.0267
CV AUC-10fold (std)	0.0354	0.0303	-0.0051

Interpretación. La CV AUC-10fold incluso *mejora* con la Y estricta (+0.0267), señal de que cuando la operacionalización de la variable es más limpia, la generalización del modelo aumenta. La AUC-ROC en prueba cae moderadamente (−0.031) pero permanece sobre el azar. La caída de F1 (−0.29) se explica por la menor prevalencia (0.31 vs 0.43): con un umbral fijo de 0.5, muchos positivos se pierden; la discriminación (AUC) sigue alta. *Las relaciones estructurales detectadas por el modelo son robustas a la elección de la operacionalización.*

8 Interpretabilidad con valores SHAP

8.1 Fundamento metodológico

Los valores SHAP [2] descomponen cada predicción individual del modelo como una suma de contribuciones aditivas por variable:

$$f(x_i) = \phi_0 + \sum_{j=1}^p \phi_{ij},$$

donde $\phi_0 = \mathbb{E}[f(X)]$ es la predicción media del modelo (valor base) y ϕ_{ij} es la contribución de la variable j a la predicción de la observación i . Las propiedades de eficiencia, simetría, linealidad y ausencia de efecto fantasma que caracterizan a los valores de Shapley garantizan que la descomposición sea la única que satisface simultáneamente estos axiomas de equidad [2]. La importancia global de la variable j se define como la esperanza del valor absoluto de su contribución: $\text{Imp}_j = \mathbb{E}[|\phi_{ij}|]$, lo que permite ordenar variables de acuerdo con su impacto promedio sobre las predicciones, independientemente del signo de la relación.

Para los árboles de decisión —tanto Random Forest como Gradient Boosting— **TreeExplainer** calcula los valores SHAP de manera exacta en tiempo polinomial, sin recurrir a aproximaciones por permutación. Esto elimina la varianza de estimación asociada a los métodos de aproximación y garantiza consistencia entre predicción y explicación.

8.2 Importancia global: del modelo demográfico al modelo social

La comparación entre la distribución de importancia SHAP en el modelo de cuatro variables y la del modelo ampliado constituye el hallazgo interpretativo central del trabajo (Figura 9).




Figure 7: *

Especificación de 4 variables (referencia)




Figure 8: *

Especificación de 16 variables (modelo ampliado)

Figure 9: Importancia media absoluta SHAP ($\mathbb{E}[|\phi_j|]$) por variable. Izquierda: modelo de referencia con 4 variables. Derecha: modelo ampliado con 16 variables. La diversificación de la distribución de importancia entre ambas especificaciones ilustra cómo la ampliación del *feature set* modifica sustancialmente la estructura explicativa del modelo.

Con la especificación de cuatro variables, **edad** y **edad_cuadrado** concentran conjuntamente el 76.5% de la importancia SHAP total, con **sexo** (15.3%) y **educacion_grupo** (8.2%) como predictores secundarios. El modelo resultante es esencialmente demográfico: la

propensión al consumo varía principalmente según el ciclo de vida del individuo, con variación residual asociada al género y al nivel educativo. Esta estructura refleja la restricción impuesta por la escasez de covariables, no necesariamente la estructura causal subyacente.

Al incorporar las 16 variables, el perfil de importancia cambia de manera radical. Los valores SHAP del RF Tuneado revelan que **probaria_sustancias** ($\mathbb{E}[|\phi|] = 0.046$, 17.1%) y **amigos_consumen** ($\mathbb{E}[|\phi|] = 0.044$, 16.2%) adquieren una importancia comparable a la de **edad** individual ($\mathbb{E}[|\phi|] = 0.053$, 19.9%), ocupando conjuntamente las cuatro primeras posiciones junto con **edad_cuadrado** (19.3%). Este resultado es de primera relevancia económica y social: indica que la exposición al consumo en el entorno próximo (red social de pares) y la disposición actitudinal hacia el consumo son predictores de propensión tan informativos como la posición en el ciclo de vida. Esta evidencia es coherente con las predicciones de la Teoría del Aprendizaje Social [1]: el comportamiento de consumo se modela en parte por observación e imitación de referentes cercanos, y no sólo por preferencias individuales inducidas por la edad.

Table 11: Importancia SHAP media absoluta ($\mathbb{E}[|\phi_j|]$) de las diez variables más relevantes en el RF Tuneado (16 variables, conjunto de prueba $n = 681$). La columna % reporta la participación de cada variable en la importancia total.

Rango	Variable	$\mathbb{E}[\phi_j]$	%
1	edad	0.053	19.9%
2	edad_cuadrado	0.052	19.3%
3	probaria_sustancias	0.046	17.1%
4	amigos_consumen	0.044	16.2%
5	riesgo_marihuana_frecuente	0.011	4.0%
6	sexo_label_Mujer	0.011	4.0%
7	familiares_consumen	0.009	3.5%
8	cannabis_medicinal	0.009	3.4%
9	riesgo_marihuana_ocasional	0.009	3.2%
10	n_hijos	0.007	2.7%

La Tabla 11 permite cuantificar con precisión el redibujo de la estructura explicativa. Las cuatro variables más importantes concentran el 72% de la importancia total: dos de ellas (**probaria_sustancias** y **amigos_consumen**) no estaban disponibles en el modelo de referencia. En contraste, **sexo** —tercer predictor en la especificación reducida (15.3%)— cae al sexto lugar (4.0%), evidenciando que su relevancia en el modelo de cuatro variables era en parte un artefacto de la ausencia de información sobre la red social. En el espacio

ampliado, el género aporta señal residual una vez que se controla por el entorno de pares y la actitud individual.

Asimismo, `riesgo_marihuana_frecuente` (4.0%) y `familiares_consumen` (3.5%) constituyen predictores secundarios de relevancia no despreciable. El primero es coherente con el *Health Belief Model*: una percepción de riesgo reducida ante el consumo frecuente se asocia positivamente con mayor propensión reportada. El segundo extiende la hipótesis de aprendizaje social al ámbito familiar, complementando la influencia de pares.

8.3 Distribución individual de contribuciones




Figure 10: SHAP *summary plot* del modelo ampliado (16 variables). Cada punto representa una observación del conjunto de prueba; el eje horizontal indica la magnitud y signo de la contribución SHAP (ϕ_{ij}); el color codifica el valor de la variable (rojo = valor alto, azul = valor bajo). Las variables se ordenan verticalmente por importancia media decreciente.




Figure 11: Dependencia parcial SHAP para la edad — relación no monótona capturada por el RF Tuneado.

El gráfico de dependencia confirma la forma funcional implícita: la contribución a la propensión es positiva en cohortes jóvenes y decae con la edad, con un patrón que el modelo lineal aproxima sólo en promedio. Esto justifica empíricamente la ventaja de los modelos no lineales sobre la regresión logística cuando el feature set incluye variables de ciclo de vida.

9 Ética, sesgos y limitaciones

9.1 Sesgos del dato

Autoreporte y deseabilidad social. La encuesta captura comportamientos socialmente estigmatizados. Es bien documentado que el autoreporte de consumo subestima la prevalencia real, y que ese subreporte se correlaciona con la percepción de riesgo legal y social. Por construcción, el modelo aprende propensión a *reportar* consumo, no propensión a *consumir*.

Sesgo de selección por cobertura de precio. La submuestra con precio ($n \approx 755$) está fuertemente seleccionada hacia personas más expuestas al mercado. Por ello el benchmark con precio se reporta como exploratorio, y los modelos de ML se entrenan sobre la muestra amplia sin precio.

Brecha *train-test* residual. El RF Tuneado exhibe AUC en entrenamiento de 0.760 frente a 0.699 en prueba (brecha = 0.060). La regularización explícita (`max_depth=15`, `min_samples_leaf=25`) redujo esta brecha desde 0.094, y la curva de aprendizaje —estable alrededor de 0.057 en todo el rango de tamaños muestrales— descarta memorización. El sobreajuste residual refleja el optimismo estructural del bagging sobre datos in-bag: los árboles del RF se construyen sobre muestras bootstrap, por lo que su evaluación sobre el conjunto de entrenamiento completo mezcla observaciones in-bag y out-of-bag, sobreestimando sistemáticamente el desempeño. El CV5 AUC (0.703 ± 0.007) es el estimador no sesgado de referencia.

Sesgo de medición en la Y. La discrepancia entre `consumo_12m` y `K_03` (Sección 4.3) introduce ruido. La robustez (Sección 7.4) muestra que las conclusiones cualitativas se mantienen, pero un trabajo definitivo debería reconciliar la construcción de la variable.

9.2 Riesgos del uso del modelo

1. **Perfilado individual.** Con $AUC \approx 0.73$, las distribuciones de propensión por grupo se solapan sustancialmente. Usar el modelo para decisiones sobre personas (perfilado policial, decisiones laborales, vigilancia escolar) sería un mal uso: el costo social del falso positivo es severo dado el estigma asociado.
2. **Asociaciones, no causalidad.** Los SHAP muestran asociaciones. Que el modelo asigne mayor probabilidad a hombres jóvenes no implica causalidad; la edad y el sexo están correlacionados con factores no observados (red social, exposición, entorno).
3. **Estigma reforzado.** Publicar mapas o perfiles de consumo puede reforzar estereotipos. La comunicación pública debe privilegiar lecturas agregadas sobre lecturas individuales.

9.3 Uso responsable propuesto

El modelo se propone como herramienta **agregada** para: *(i)* estimar tamaños de mercado bajo escenarios regulatorios; *(ii)* apoyar el diseño tributario simulando bases de contribuyentes por estratos amplios; *(iii)* priorizar segmentos para política preventiva. No se recomienda para decisiones individuales ni para focalización geográfica fina sin análisis adicional de equidad.

10 Implicaciones económicas y de política pública

Tamaño y demografía del mercado. El GBM tuneado permite clasificar la población encuestada en grupos de mayor o menor propensión, insumo para una proyección poblacional

con estructura etaria del DANE. La concentración en cohortes 18–35 años sugiere un mercado potencial relativamente acotado en términos de personas, pero con probable alta frecuencia de consumo en el segmento activo.

Diseño tributario. Si Colombia avanzara hacia un marco regulado, la base de contribuyentes (vía IVA u otro impuesto al consumo) estaría concentrada en cohortes jóvenes-masculinas. La elasticidad-precio probablemente es elevada en ese segmento, lo cual exige cautela: un impuesto demasiado alto desplazaría la demanda al mercado ilegal, anulando el efecto recaudatorio. Una proyección de recaudo creíble requiere acoplar este modelo de propensión con una elasticidad-precio estimada limpiamente, algo que la submuestra disponible no permite.

Política preventiva. Las cohortes 18–25 años son las de mayor propensión observada. Esto justifica focalizar campañas de información y prevención en ese rango y diseñar mecanismos diferenciados por sexo.

Trabajo futuro. Las líneas más prometedoras son: *(i)* resolver la construcción de la variable objetivo a partir de K_03 directo para eliminar la discrepancia documentada; *(ii)* estimar elasticidad-precio con un diseño que corrija el sesgo de selección de la submuestra con precio; *(iii)* incorporar variables geográficas (departamento, zona urbana/rural) si se dispone de una versión no anonimizada de la encuesta, para capturar heterogeneidad territorial que el modelo actual no puede identificar; *(iv)* estimar un modelo de dos etapas (*hurdle model*) que separe la decisión de consumir de la intensidad del consumo, conectando directamente con la estimación de recaudo tributario.

11 Reproducibilidad

El proyecto está organizado para que cualquier análisis pueda repetirse de forma transparente:

- **Pipeline CLI:** `python -m cannabis_tax.cli pipeline` ejecuta limpieza, validación y construcción de la base modeladora.
- **Notebook 01:** `notebooks/01_eda_y_mco_propension.ipynb` — EDA y benchmark.
- **Notebook 03:** `notebooks/03_modelos_ml.ipynb` — entrenamiento inicial de RF/XGBoost/GBM.
- **Notebook 04:** `notebooks/04_pca.ipynb` — exploración PCA complementaria.
- **Notebook 05:** `notebooks/05_validacion_semanas10_12.ipynb` — validación cruzada, búsqueda de hiperparámetros, selección del modelo final.

- **Notebook 06:** `notebooks/06_interpretabilidad_etica.ipynb` — SHAP, robustez con Y alternativa y discusión ética.
- **Tests:** `make test` corre la suite de pruebas unitarias del paquete.

Todas las tablas y figuras del paper se exportan automáticamente desde el código y residen en `reports/tables/` y `reports/figures/`.

12 Conclusiones

Este trabajo recorrió el ciclo completo de modelado de propensión al consumo de marihuana en Colombia: integración de datos, estimación de benchmarks econométricos, entrenamiento y *tuning* de modelos de *machine learning* sobre el espacio ampliado de 16 variables, interpretabilidad SHAP y análisis de robustez. La evidencia acumulada permite formular cuatro conclusiones sustantivas.

Primera: el benchmark econométrico es una referencia exigente y no trivial.

Con sólo cuatro regresores demográficos —edad, edad al cuadrado, sexo y nivel educativo—, el Probit alcanza $AUC-ROC = 0.7027$ y $CV5 AUC = 0.6648$, superando a todos los algoritmos de *machine learning* con hiperparámetros de referencia en la misma especificación. Este resultado es coherente con la literatura: en espacios de variables reducidos con relaciones aproximadamente aditivas, el sesgo del estimador lineal es bajo y la ganancia de complejidad funcional no compensa su costo en varianza [5]. El benchmark no es una formalidad; es una restricción activa que cualquier modelo más complejo debe superar para justificarse.

Segunda: el *tuning* disciplinado es condición necesaria pero no suficiente.

Sin ajuste de hiperparámetros, el *machine learning* no supera al benchmark. El GBM tuneado sobre la especificación de cuatro variables apenas supera al Probit en $CV5 AUC (+0.007)$, insuficiente para establecer ventaja estructural. La lección metodológica es que la elección del algoritmo es secundaria respecto a la disciplina en su calibración; pero con sólo cuatro variables, el espacio de mejora es inherentemente limitado.

Tercera: el RF Tuneado sobre 16 variables es el modelo ganador con justificación metodológica sólida. Al ampliar el *feature set* y tunear con regularización explícita, el RF Tuneado obtiene $CV5 AUC = 0.703 \pm 0.007$ —una ganancia de $+0.038$ sobre el benchmark y $+0.032$ sobre el GBM tuneado de cuatro variables. Su ventaja sobre el GBM tuneado de 16 variables se evidencia en la varianza de generalización (± 0.007 vs. ± 0.021). La brecha *train-test* de 0.060 (reducida desde 0.094 mediante `max_depth=15` y `min_samples_leaf=25`) y la curva de aprendizaje estable confirman que el sobreajuste residual es el optimismo estructural esperado del bagging, no memorización. El hallazgo interpretativo más relevante proviene del análisis SHAP: con cuatro variables, `edad` y `edad_cuadrado` concentraban el 76.5% de la importancia SHAP. Con 16 variables,

`probaria_sustancias` (17.1%) y `amigos_consumen` (16.2%) alcanzan importancia comparable a `edad individual` (19.9%), mientras el sexo cae del tercer al sexto lugar. Esta redistribución valida empíricamente las predicciones de la Teoría del Aprendizaje Social.

Cuarta: la robustez estructural del modelo es satisfactoria, pero persisten limitaciones documentadas. El análisis de robustez con $Y_{\text{alt}} = \mathbb{I}\{K_{03} = 1\}$ confirma que las relaciones estructurales son estables ante cambios en la operacionalización de la variable objetivo. No obstante, la discrepancia de 898 casos entre `consumo_12m` y `K_03` debe declararse como limitación sustantiva; un trabajo definitivo deberá reconciliar la variable objetivo e imputar los valores faltantes de `regimen_salud` para recuperar los 581 registros excluidos.

En síntesis, el modelo se propone como insumo para análisis agregados de mercado, diseño tributario y focalización de política preventiva. Su uso para perfilado individual implicaría un error categorial: con $\text{AUC} \approx 0.70$, las distribuciones de propensión por grupo se solapan sustancialmente, y el costo social del falso positivo en un dominio estigmatizado es inaceptable. Esta distinción —entre uso agregado legítimo y uso individual inapropiado— no es un epílogo ético decorativo; es parte constitutiva del diseño responsable del modelo.

References

- [1] Becker, G. & Murphy, K. (1988). A Theory of Rational Addiction. *Journal of Political Economy*, 96(4), 675–700.
- [2] Lundberg, S. M. & Lee, S.-I. (2017). A Unified Approach to Interpreting Model Predictions. *NeurIPS 2017*.
- [3] DANE. Encuesta Nacional de Consumo de Sustancias Psicoactivas.
- [4] Friedman, J. H. (2001). Greedy function approximation: A gradient boosting machine. *Annals of Statistics*, 29(5), 1189–1232.
- [5] Hastie, T., Tibshirani, R. & Friedman, J. (2009). *The Elements of Statistical Learning* (2nd ed.). Springer.