

Propensión al Consumo de Marihuana en Colombia

Benchmark Económico, Modelos de *Machine Learning* e Interpretabilidad SHAP

Santiago Tupaz, Moisés Quintero, Vanessa Rodrigues

Universidad EAFIT, Programa de Economía

Profesores: Paula María Almonacid Hurtado & Carlos Alberto Cerro Espinal

12 de mayo de 2026

Contexto y motivación

- **Tendencia global:** más de 40 países han legalizado el cannabis en alguna forma.
- **Colombia:** el debate sobre regulación incorpora hoy preguntas económicas concretas (tamaño de mercado, base tributaria, política preventiva).
- **Pregunta previa:** antes de cualquier simulación fiscal, hay que caracterizar empíricamente **quién consume** y **con qué propensión**.
- **Insumo natural:** la Encuesta Nacional de Consumo de Sustancias Psicoactivas (ENCSPA).

Brecha que aborda este trabajo

- Pocos modelos comparan rigurosamente **benchmark econométrico vs. *machine learning*** en este dominio para Colombia.
- Escasa discusión estructurada de **ética y sesgos** en estudios de consumo de drogas con datos de encuesta.
- Necesidad de **interpretabilidad** (no sólo precisión) cuando el modelo se usa para política pública.

Nuestra contribución: pipeline reproducible + comparación honesta + interpretabilidad SHAP + frontera ética explícita.

¿Por qué importa?

Dimensión económica:

- Tamaño potencial del mercado
- Base tributaria si se legaliza
- Elasticidad-precio del segmento

Dimensión social:

- Focalización de prevención
- Reducción del estigma vía datos
- Uso responsable de IA en política

Pregunta central

¿Qué factores sociodemográficos observables se asocian con la probabilidad de reportar consumo de marihuana en los últimos doce meses en Colombia, y cuánto mejora la predicción al pasar de un benchmark econométrico a modelos de *machine learning*?

Componentes:

- 1 **Descriptivo-causal:** signo, magnitud y estabilidad de los predictores.
- 2 **Predictivo:** ganancia del ML sobre el lineal con un *feature set* ampliado (red social, actitud, salud mental, percepción de riesgo).

Variable objetivo y unidad de análisis

Variable dependiente: $\text{propension_12m} \in \{0, 1\}$ — reportó consumo de marihuana en los últimos 12 meses (base limpia, derivada de K_03 + señales auxiliares).

Unidad de análisis: individuo encuestado (ENCSPA).

Tipo de problema: clasificación binaria.

Nota crítica: la construcción de propension_12m difiere de K_03 raw en 898 casos. Se documenta como limitación y se atiende con un análisis de robustez (Y estricta = $K_03=1$).

Objetivos

General: construir un pipeline reproducible que compare benchmark econométrico y *machine learning* para la propensión al consumo, con interpretabilidad y reflexión ética explícitas.

Específicos:

- 1 Integrar y limpiar la base de la ENCSPA con módulos sociodemográficos.
- 2 Estimar benchmark MCO/Probit y modelos ML comparables.
- 3 Validar con CV-10 y tunear hiperparámetros del modelo final.
- 4 Interpretar con valores SHAP y verificar robustez.
- 5 Discutir sesgos, ética y usos legítimos del modelo.

Datos y fuentes — 5 módulos integrados

Fuentes

- Base limpia de consumo (cap. K)
- Módulo personas (sexo, edad)
- Módulo d2 (educación, hijos)
- Módulo g (red social, actitud)
- Módulo d (laboral, salud, percepción)

Cobertura

- $n = 3\,982$ individuos
- 16 features, 0% nulos (salvo `regimen_salud`: 11.2%)
- `consumo_12m`: 1 719 positivos
- Precio: submuestra exploratoria ($n \approx 755$)

Decisión: ML sobre la muestra amplia sin precio.

Pipeline reproducible

- 1 `python -m cannabis_tax.cli pipeline`: limpieza, validación y construcción de la base modeladora.
- 2 Notebook 01: EDA + benchmark MCO/Probit.
- 3 Notebook 03: entrenamiento RF, XGBoost, GBM.
- 4 Notebook 05: CV-10, búsqueda de hiperparámetros, selección del modelo final.
- 5 Notebook 06: SHAP + robustez + ética.

Tests: `make test` corre la suite unitaria.

MCO (LPM):

$$y_i = \beta_0 + \beta_2 edad_i + \beta_3 edad_i^2 + \beta_4 mujer_i + \beta_5 educacion_i + u_i$$

con errores HC1.

Probit:

$$\Pr(y_i = 1 \mid X_i) = \Phi(\alpha_0 + \alpha_2 edad_i + \alpha_3 edad_i^2 + \alpha_4 mujer_i + \alpha_5 educacion_i)$$

con efectos marginales promedio.

Roles: referencia interpretable y punto de comparación.

Feature set ampliado — 16 variables

Grupo	Variables
Demográficas base	edad, edad ² , sexo, educación
Estructura familiar	n_hijos
Red social (G_01, G_02)	familiares_consumen, amigos_consumen
Actitud (G_04, G_09)	probaria_sustancias, cannabis_medicinal
Situación socioeconómica (D_02, D_07)	actividad_laboral, regimen_salud
Salud mental PHQ-2 (D_09, D_10)	sintomas_depresivos, anhedonia
Percepción de riesgo (D_11_F, D_11_G)	riesgo_marihuana_ocasional/frecuente

Todos con 0% de nulos salvo regimen_salud (11.2%). Categóricas con *one-hot encoding*.

Modelos de Machine Learning

- **Random Forest:** *bagging*, 300 árboles, `max_depth=7`.
- **XGBoost:** *boosting* secuencial, ponderado por prevalencia.
- **Gradient Boosting (sklearn):** *boosting* conservador, `max_depth=3`.

Reglas de comparación:

- *Feature set* ampliado de 16 variables (ver tabla anterior).
- Mismo train/test split estratificado (`random_state=42`).
- Métricas: Accuracy, AUC-ROC, F1, CV AUC (5 y 10 folds).

Validación y selección

- ① **CV-10**: estabilidad y solapamiento entre modelos.
- ② **Curvas de aprendizaje**: control de *overfitting*.
- ③ **RandomizedSearchCV**: 60 combinaciones $\times$ 5 folds sobre el GBM.
- ④ **Criterios**: AUC-ROC, F1, brecha train-validation, plausibilidad económica.

No se evalúa sólo precisión: la argumentación pesa tanto como el número.

Benchmark econométrico — una referencia exigente

Con sólo 4 variables demográficas, los modelos lineales fijan una barra alta:


Modelo	Accuracy	AUC-ROC	F1	CV AUC (5-fold)
MCO (LPM)	0.6611	0.7033	0.5823	—
Probit	0.6611	0.7027	0.5817	0.6648
Random Forest	0.6397	0.6600	0.5689	0.6316
Gradient Boosting	0.6373	0.6947	0.5511	0.6667
GBM Tuneado	0.6573	0.6959	0.5891	0.6714

Hallazgo: con hiperparámetros por defecto, el ML *no* supera al benchmark.

El GBM tuneado apenas gana en CV5: +0.007 sobre Probit, +0.005 sobre AUC de prueba.

El benchmark no es formalidad; es una **restricción activa**.

¿Por qué el ML no supera al benchmark por defecto?



CV-10 — solapamiento sustancial entre modelos

Interpretación:

- Relación aproximadamente aditiva en 4 variables $\Rightarrow$ MCO minimiza sesgo.
- ML sin regularización paga varianza sin ganancia de sesgo.
- Las cajas de CV-10 se solapan: diferencias no robustas.
- El CV5 AUC del GBM tuneado (0.671) apenas supera al Probit (0.665).

Búsqueda de hiperparámetros sobre 4 variables — 300 evaluaciones

Estrategia: RandomizedSearchCV, 60 combinaciones $\times$ 5 folds estratificados.

Hiperparámetro	Valor óptimo
n_estimators	157
max_depth	2
learning_rate	0.042
subsample	0.972
min_samples_leaf	26
max_features	log2

Patrón interpretable:

Árboles muy superficiales (depth=2) + tasa baja + submuestra alta = **regularización agresiva**.

El ML gana no por mayor complejidad, sino por mejor control del compromiso **sesgo-varianza**.

Pero la ganancia sobre el benchmark es marginal con sólo 4 variables.

Modelo ampliado — 16 variables, 7 grupos teóricos

Muestra efectiva: $n = 3\,401$ (eliminación por lista; 11.2% de nulos en `regimen_salud`).

Modelo (16 feat.)	n	Accuracy	AUC-ROC	CV5 AUC
Random Forest	3 401	0.6397	0.6519	0.677 ± 0.018
Gradient Boosting	3 401	0.6490	0.6949	0.699 ± 0.019
GBM Tuneado (16 vars)	3 401	0.6505	0.6990	0.704 ± 0.021
RF Tuneado (16 vars)	3 401	0.6667	0.6995	0.703 ± 0.007
<i>Ref.: Probit (4 feat.)</i>	<i>3 980</i>	—	<i>0.7027</i>	<i>0.665</i>

Lectura clave: el CV5 AUC del RF Tuneado (0.703) supera al benchmark Probit (0.665) en **+0.038** y al GBM tuneado (4 vars) en **+0.032**. La varianza del RF (± 0.007) es **tres veces menor** que la del GBM tuneado (± 0.021), confirmando su estabilidad de generalización.

Selección del modelo — ¿por qué RF Tuneado?

Criterio: menor varianza de CV5 + brecha *train-test* controlada + máximo CV5 AUC.

Hiperparámetros (RF regularizado):


Parámetro	Valor
n_estimators	400
max_depth	15
max_features	0.30
min_samples_leaf	25
min_samples_split	10
bootstrap	True

Diagnóstico de ajuste:

- AUC train = 0.760, AUC test = 0.700
- Brecha = **0.060** (antes 0.094)
- Curva de aprendizaje **estable**: no memorización
- CV5 ± 0.007 : la menor de todos los modelos

Regularización explícita: profundidad + hojas mínimas + bagging.

Curva de aprendizaje — RF Tuneado (16 variables)



¿Por qué SHAP?

Problema: el RF Tuneado es una caja negra. Sin interpretabilidad, no es útil para política pública.

SHAP (Lundberg & Lee, 2017): descompone cada predicción como suma de contribuciones por variable:

$$f(\mathbf{x}_i) = \phi_0 + \sum_{j=1}^p \phi_{ij}$$


La importancia global: $\text{Imp}_j = \mathbb{E}[|\phi_{ij}|]$

Ventaja clave: TreeExplainer calcula valores SHAP *exactos* para árboles de decisión, sin aproximación por permutación. Válido tanto para Random Forest como para GBM.

Uso aquí: comparar la estructura explicativa del modelo de 4 variables vs. el modelo de 16 variables (RF Tuneado).


Importancia SHAP — del modelo demográfico al modelo social

4 variables (GBM Tuneado — referencia)



Edad+edad² concentran **76.5%**.
Sexo ocupa el 3^{er} lugar (15.3%).
Modelo demográfico puro.

16 variables (RF Tuneado ★)



Red social y actitud alcanzan importancia comparable a la edad (19.9%). Sexo cae al 6^{to} lugar (4.0%).


Top 10 variables — importancia SHAP (RF Tuneado, 16 variables)

#	Variable	$\mathbb{E}[\phi_j]$	%
1	edad	0.053	19.9%
2	edad_cuadrado	0.052	19.3%
3	probaria_sustancias	0.046	17.1%
4	amigos_consumen	0.044	16.2%
5	riesgo_marihuana_frecuente	0.011	4.0%
6	sexo_label_Mujer	0.011	4.0%
7	familiares_consumen	0.009	3.5%
8	cannabis_medicinal	0.009	3.4%
9	riesgo_marihuana_ocasional	0.009	3.2%
10	n_hijos	0.007	2.7%


Lectura: probaria_sustancias (17.1%) y amigos_consumen (16.2%) son *tan importantes como la edad individual* (19.9%). El sexo —3^{er} predictor con 4 variables (15.3%)— cae al 6^{to} lugar (4.0%).

Validación: Teoría del Aprendizaje Social (Bandura) + *Health Belief Model*.

SHAP summary plot — dirección e intensidad por individuo



Dependencia parcial SHAP — Edad



Relación no monótona: contribución positiva en cohortes jóvenes, decreciente con la edad.
Esta forma funcional no lineal justifica el uso del RF sobre modelos lineales, y es consistente con la hipótesis de ciclo de vida del consumo.

Análisis de robustez — variable objetivo alternativa

Motivación: consumo_12m difiere de K_03 en 898 casos (22.6% de los consumidores declarados).

Hallazgo: en la especificación de 4 variables (GBM Tuneado), reentrenar con $Y_{alt} = \mathbb{I}\{K_03 = 1\}$ produce:

Métrica	Y original	Y estricta	Δ
AUC-ROC (prueba)	0.6959	0.6870	-0.009
CV AUC-5fold (media)	0.6714	0.6951	+0.027

Conclusión: el CV AUC *mejora* con la Y estricta (+0.027), señal de que una operacionalización más limpia del objetivo mejora la generalización. Las relaciones estructurales son estables ante la elección de Y.

Próximo paso: reconciliar las 898 discrepancias y re-estimar el RF Tuneado con Y_{alt} .

Sesgos del dato

- **Autoreporte y deseabilidad social:** el modelo aprende propensión a *reportar*, no a *consumir*. Subreporte correlacionado con percepción de riesgo legal.
- **Sesgo de selección por precio:** la submuestra con precio ($n \approx 755$) está sesgada hacia personas más expuestas al mercado.
- **Sesgo de medición en Y:** discrepancia documentada consumo_12m vs K_03. Mitigada con análisis de robustez.

Riesgos del uso del modelo

- ❶ **Perfilado individual:** $AUC \approx 0.73$ implica solapamiento alto entre grupos. *No usar* para decisiones sobre personas (policial, laboral, escolar).
- ❷ **Asociaciones $\neq$ causalidad:** edad y sexo correlacionan con factores no observados (red social, entorno).
- ❸ **Estigma reforzado:** mapas y perfiles públicos refuerzan estereotipos. Privilegiar lecturas agregadas.

Uso responsable propuesto

Sí (uso agregado):

- Estimar tamaño de mercado bajo escenarios regulatorios.
- Diseño tributario simulando bases de contribuyentes por estratos amplios.
- Priorizar segmentos para política preventiva.

No (uso individual):

- Decisiones sobre personas específicas.
- Focalización geográfica fina sin análisis de equidad.
- Predicciones puntuales sin intervalos de incertidumbre.

Diseño tributario:

- Base concentrada en cohortes jóvenes-masculinas.
- Elasticidad-precio probablemente alta $\Rightarrow$ impuesto excesivo desplaza al mercado ilegal.
- Recaudo creíble requiere acoplar este modelo con una elasticidad estimada limpia.

Política preventiva:

- Focalizar en 18–25 años, diferenciada por sexo.
- Aprovechar la sensibilidad de la cohorte a intervenciones tempranas.

Cuatro conclusiones sustantivas

- ❶ **El benchmark es una restricción activa.** Probit con 4 variables: CV5 AUC = 0.6648. Ningún modelo ML con las mismas 4 variables lo supera de forma consistente.
- ❷ **El *tuning* es condición necesaria, no suficiente.** GBM tuneado (4 feat.): CV5 = 0.6714 — apenas +0.007 sobre el benchmark. El ML con pocas variables bien modeladas no tiene ventaja estructural sobre la regresión lineal.
- ❸ **Las 16 variables y el RF Tuneado (regularizado) generalizan mejor.** CV5 AUC = **0.703** (± 0.007), superior al benchmark en +0.038 y al GBM tuneado de 4 variables en +0.032. Brecha *train-test* = 0.060 — reducida desde 0.094 con regularización explícita (`max_depth=15`, `min_samples_leaf=25`).
- ❹ **El hallazgo interpretativo es el más valioso.** SHAP sobre RF Tuneado: *probaria_sustancias* (17.1%) y *amigos_consumen* (16.2%) alcanzan importancia comparable a *edad* (19.9%). El sexo cae del 3^{er} al 6^{to} lugar. La red social y la actitud *co-determinan* la propensión tanto como el ciclo de vida.

Lecciones metodológicas

- El **tuning** importa más que el **algoritmo** en muestras moderadas: la elección entre RF, XGBoost o GBM es secundaria respecto a su calibración adecuada.
- La **riqueza de features es complementaria al tuning**, no sustituta. Ampliar el feature set con variables teóricamente justificadas cambia la estructura interpretativa y mejora la generalización (CV5).
- El **CV AUC es más informativo que el AUC en prueba** cuando la muestra es moderada: la varianza de la partición puede enmascarar ganancias reales de generalización.
- La **interpretabilidad no es decorativa**: sin SHAP, no habríamos detectado que el género cae 3 posiciones al controlar por la red social, validando la Teoría del Aprendizaje Social.
- **Documentar limitaciones es parte del trabajo**: discrepancia Y/K_03, nulos en `regimen_salud`, ausencia de variables geográficas.

Próximos pasos

- **Reconciliar Y**: resolver las 898 discrepancias entre consumo_12m y K_03 para eliminar el ruido en la variable objetivo.
- **Imputar** regimen_salud (11.2% nulos) con imputación múltiple o modelo predictivo, recuperando ~ 581 observaciones adicionales.
- **Nuevo *tuning* sobre 16 variables con Y_{alt}** : re-estimar el RF Tuneado con la variable objetivo reconciliada; el CV AUC mejoró +0.027 con la Y estricta en la especificación de 4 variables.
- **Elasticidad-precio**: estimar con diseño que corrija el sesgo de selección de la submuestra con datos de precio ($n \approx 755$).
- **Modelo *hurdle***: decisión de consumir + intensidad, para conectar directamente con la simulación de recaudo tributario.

Preguntas y discusión

Santiago Tupaz Moisés Quintero Vanessa Rodrigues

Universidad EAFIT

Profesores: Paula María Almonacid Hurtado & Carlos Alberto Cerro Espinal