

Universidad EAFIT

Programa de Economía

Ciencia de los Datos para las Finanzas, la Economía y los Negocios

Propensión al Consumo de Marihuana en Colombia

Benchmark Econométrico y Modelos de Machine Learning
con Interpretabilidad SHAP

Autores:

Santiago Tupaz^{1,2}

Moisés Quintero¹

Vanessa Rodrigues¹

¹ Universidad EAFIT, Programa de Economía, Medellín, Colombia

² Universidad Nacional de Colombia, Programa de Estadística, Sede Medellín

Profesora Supervisora:

Paula María Almonacid Hurtado

Universidad EAFIT

Medellín, Colombia

12 de mayo de 2026

Abstract

Este trabajo modela la propensión individual a reportar consumo de marihuana en los últimos doce meses en Colombia, integrando un benchmark econométrico clásico con modelos de *machine learning* y un análisis de interpretabilidad mediante valores SHAP. La base empírica proviene de la Encuesta Nacional de Consumo de Sustancias Psicoactivas y se complementa con módulos sociodemográficos (capítulo D2) y de personas. Sobre 3 980 observaciones efectivas se estiman dos benchmarks (MCO y Probit) y tres modelos de *machine learning* (Random Forest, XGBoost y Gradient Boosting), todos sobre el mismo conjunto de variables explicativas para asegurar comparabilidad. Tras la búsqueda aleatoria de hiperparámetros con validación cruzada de cinco pliegues, el *Gradient Boosting* tuneado supera al benchmark en *AUC-ROC* (0.7278 vs 0.7232) y en *F1-Score* (0.6129 vs 0.5982), mientras que la validación cruzada de diez pliegues confirma estabilidad. La interpretabilidad SHAP muestra que la edad y su término cuadrático concentran cerca del 77% de la importancia absoluta del modelo final, seguido por sexo (15%) y educación (8%). Un análisis de robustez con una definición alternativa estricta de la variable objetivo ($K_03 = 1$) confirma que las relaciones estructurales no dependen de la operacionalización elegida. Se discuten finalmente los sesgos del autoreporte, los riesgos de perfilado individual y las implicaciones para el diseño de un eventual marco tributario y para política preventiva.

Palabras clave: marihuana, propensión al consumo, MCO, Probit, Gradient Boosting, SHAP, ética del *machine learning*, Colombia.

Contents

1	Introducción	4
2	Pregunta de investigación	4
3	Marco conceptual y trabajos relacionados	5
4	Datos y construcción de la base	5
4.1	Fuentes de información	5
4.2	Variables priorizadas	6
4.3	Discrepancia entre consumo_12m y K_03: una nota metodológica	6
4.4	Disponibilidad y calidad de datos	7
4.5	Reglas de limpieza y <i>feature engineering</i>	7
5	Estrategia econométrica: el benchmark	7
5.1	Modelo lineal de probabilidad (MCO)	7
5.2	Modelo Probit	8
5.3	Resultados del benchmark	8
6	Modelos de Machine Learning	9
6.1	Especificación de los modelos	9
6.2	Tabla comparativa de desempeño	9
7	Validación, robustez y selección del modelo final	11
7.1	Validación cruzada de 10 pliegues	11
7.2	Curvas de aprendizaje	11
7.3	Búsqueda de hiperparámetros	12
7.4	Selección razonada del modelo final	12
7.5	Análisis de robustez con Y alternativa estricta	13
8	Interpretabilidad con valores SHAP	14
8.1	Metodología	14
8.2	Importancia global	14
8.3	Lectura individual	15
9	Ética, sesgos y limitaciones	16
9.1	Sesgos del dato	16
9.2	Riesgos del uso del modelo	17
9.3	Uso responsable propuesto	17
10	Implicaciones económicas y de política pública	17

11 Reproducibilidad	18
12 Conclusiones	18

1 Introducción

La discusión sobre la regulación de la marihuana en Colombia ha tenido recientemente un giro pragmático: ya no se limita a la dimensión penal o de salud pública, sino que incorpora preguntas económicas concretas sobre el tamaño potencial del mercado, la base de contribuyentes que podría generarse bajo un marco regulado, y los segmentos demográficos donde una eventual política preventiva tendría mayor impacto. Estas preguntas requieren, antes de cualquier simulación fiscal, una caracterización empírica clara de quién consume y con qué intensidad.

Este trabajo se sitúa en esa etapa previa. El objetivo es modelar la propensión individual a reportar consumo de marihuana en los últimos doce meses, utilizando información de la Encuesta Nacional de Consumo de Sustancias Psicoactivas y un conjunto cuidadoso de controles sociodemográficos. La estrategia es comparativa: se estima primero un benchmark econométrico (MCO y Probit) y luego una familia de modelos de *machine learning* (Random Forest, XGBoost y Gradient Boosting), tras lo cual se selecciona un modelo final por validación cruzada y se interpreta con valores SHAP. El proyecto avanza así desde la teoría econométrica de variables binarias hacia la flexibilidad funcional del aprendizaje estadístico moderno, pero manteniendo la disciplina de comparar siempre los modelos contra una referencia interpretable.

Aunque el trabajo está pensado como insumo para un análisis posterior de impacto tributario, las contribuciones específicas aquí son tres: *primero*, una base de modelado reproducible y auditada (con tests unitarios y CLI) que puede reutilizarse en investigaciones futuras; *segundo*, una comparación honesta entre benchmark econométrico y *machine learning* que ilustra cuándo la ganancia predictiva del segundo justifica su menor interpretabilidad; *tercero*, un análisis estructurado de sesgos y limitaciones éticas que delimita los usos legítimos del modelo y, sobre todo, los usos que no recomendamos.

2 Pregunta de investigación

La pregunta de trabajo es la siguiente:

¿Qué factores sociodemográficos observables se asocian con la probabilidad de reportar consumo de marihuana en los últimos doce meses en Colombia, y qué tanto mejora la capacidad predictiva del modelo al pasar de un benchmark econométrico a modelos de *machine learning*?

La pregunta tiene dos componentes complementarios. El primero es *descriptivo-causal*: identificar variables observables asociadas a la propensión y reportar su signo, magnitud y estabilidad. El segundo es *predictivo*: cuantificar cuánto se gana al permitir

no-linealidades e interacciones automáticas, manteniendo el mismo conjunto de regresores que el benchmark para que la comparación sea limpia.

3 Marco conceptual y trabajos relacionados

La literatura económica sobre consumo de sustancias controladas se organiza en tres familias de modelos. La primera estima la decisión binaria de consumir mediante variables sociodemográficas, con foco en el efecto de precios e impuestos sobre la demanda [1]. La segunda explora la intensidad del consumo condicional a participar, usando modelos de selección o *two-part*. La tercera, más reciente, incorpora aprendizaje estadístico para mejorar el desempeño predictivo y descubrir interacciones complejas entre variables que el lineal estándar no captura.

En el contexto colombiano, el insumo natural es la Encuesta Nacional de Consumo de Sustancias Psicoactivas, que combina información sobre prevalencia, frecuencia, precio percibido y actitudes. Este trabajo se ubica en la primera familia (decisión binaria), pero incorpora el aporte metodológico de la tercera al comparar el benchmark con *Gradient Boosting* y al usar interpretabilidad SHAP para conectar los resultados predictivos con la lectura económica clásica.

4 Datos y construcción de la base

4.1 Fuentes de información

La base final de modelado se construyó integrando tres fuentes:

Archivo	Contenido	Llaves
base_consumo_drogas_colombia_limpia.xlsx	Variables derivadas de consumo, gasto, precio, acceso y actitudes	id_hogar, id_encuesta, id_persona, orden_persona
personas_processed.csv	Sexo, edad y variables básicas de identificación individual	directorio, secuencia_encuesta, secuencia_p, orden
d2_capitulos.csv	Escolaridad y variables sociodemográficas complementarias	directorio, secuencia_encuesta, secuencia_p, orden

Table 1: Fuentes principales para la base de modelado

La unión por llaves cubre las 3 982 observaciones de la base limpia de consumo

sin pérdida adicional en la fase de *merge*. La muestra final para las especificaciones econométricas sin precio se reduce a 3 980 porque dos observaciones tienen D2_05 = 9 (No sabe / No informa) y quedan fuera al construir la agrupación educativa estable de tres niveles.

4.2 Variables priorizadas

Para esta fase se priorizaron las variables estrictamente necesarias para el benchmark y los modelos de *machine learning* comparables:

Variable limpia	Código	Definición	Uso
consumo_12m	K_03	¿Ha consumido marihuana en los últimos 12 meses?	Variable dependiente
precio_compra	K_09, K_09_VALOR	Conocimiento y valor del precio de un cigarrillo o porro de marihuana	Regresor de interés (submuestra)
sexo	sexo	Sexo de la persona	Control demográfico
edad	edad	Edad en años cumplidos	Control demográfico
d2_05	D2_05	Nivel educativo más alto alcanzado	Control socioeconómico

Table 2: Variables principales integradas desde el inventario operativo

4.3 Discrepancia entre consumo_12m y K_03: una nota metodológica

Una auditoría interna del repositorio (24 de marzo de 2026) detectó que la variable consumo_12m en la base limpia no coincide exactamente con K_03 en los datos crudos. La distribución comparada es:

Fuente	Sí (1)	No (2)	NS/NR (9)
K_03 (cuestionario raw)	1 223	2 754	5
consumo_12m (base limpia, recodificada)	1 719	2 263 ($\equiv 0$)	—

Table 3: Comparación de la variable de propensión en su versión *raw* y en la base limpia

El cruce a nivel individuo muestra que 898 personas marcadas como consumidoras (consumo_12m=1) declararon explícitamente K_03=2 en el cuestionario. Esto sugiere que la base limpia construyó consumo_12m con una lógica más amplia, combinando probablemente consumo_vida, consumo_30d y consumo_reciente. La variable frecuencia_consumo

en la base limpia sí coincide perfectamente con `K_03` (1 223 / 2 754 / 5), lo cual refuerza esa hipótesis.

Por transparencia académica, esta discrepancia se declara explícitamente como limitación del trabajo y se atiende mediante un análisis de robustez (Sección 7.5) en el que el modelo final se reentrena con la definición estricta $Y_{\text{alt}} = \mathbb{1}\{K_03 = 1\}$.

4.4 Disponibilidad y calidad de datos

La cobertura efectiva varía sustancialmente entre variables:

- `consumo_12m`: 1 719 registros marcados como 1 sobre 3 982.
- `precio_compra`: 823 registros no nulos; 755 válidos para modelado con covariables completas.
- Edad, sexo, educación agrupable: cobertura cercana al 100%.

La submuestra con precio ($n = 755$) está fuertemente seleccionada: combina personas que conocen el precio del producto y están dispuestas a reportarlo, lo cual sesga el subconjunto hacia individuos más expuestos al mercado. Por esa razón, todo análisis con precio se reporta como exploratorio y los modelos de *machine learning* se entrenan sobre la muestra amplia sin precio ($n = 3980$).

4.5 Reglas de limpieza y *feature engineering*

La construcción siguió estas reglas: (i) unión de las tres fuentes vía llaves equivalentes; (ii) recodificación binaria de `K_03` en `propension_12m`; (iii) eliminación de códigos especiales (8, 9, 98, 99, 998, 999) en variables numéricas; (iv) transformación logarítmica del precio cuando es válido; (v) agrupación educativa en tres categorías estables: *baja*, *media* y *superior*; (vi) término cuadrático de edad para capturar la no-linealidad sugerida por la teoría del ciclo de vida del consumo.

5 Estrategia econométrica: el benchmark

5.1 Modelo lineal de probabilidad (MCO)

$$y_i = \beta_0 + \beta_1 \log(\text{precio}_i) + \beta_2 \text{edad}_i + \beta_3 \text{edad}_i^2 + \beta_4 \text{mujer}_i + \beta_5 \text{educacion}_i + u_i,$$

donde $y_i = 1$ si la persona reporta consumo en los últimos 12 meses, y u_i es ruido idiosincrásico. El MCO con errores HC1 sirve como referencia interpretable.

5.2 Modelo Probit

$$\Pr(y_i = 1 \mid X_i) = \Phi(\alpha_0 + \alpha_1 \log(\text{precio}_i) + \alpha_2 \text{edad}_i + \alpha_3 \text{edad}_i^2 + \alpha_4 \text{mujer}_i + \alpha_5 \text{educacion}_i),$$

con efectos marginales promedio para que la comparación con MCO sea directa.

5.3 Resultados del benchmark

La Tabla 4 resume tamaño muestral y ajuste; la Tabla 5, los coeficientes y efectos marginales.

Table 4: Resumen de muestra y ajuste

Modelo	N	Metrica	Valor	Incluye precio
MCO completa	3980	R2	0.091	No
MCO con precio	755	R2	0.061	Si
Probit completo	3980	Pseudo R2	0.071	No
Probit con precio	755	Pseudo R2	0.050	Si

Table 5: Resultados comparados de benchmark

Variable	MCO completa	MCO con precio	Probit completo	Probit con precio
Log precio		0.044 (0.012)		0.044 (0.012)
Mujer	-0.065 (0.016)	0.006 (0.041)	-0.064 (0.016)	0.004 (0.039)
Edad	-0.016 (0.003)	0.013 (0.008)	-0.012 (0.004)	0.010 (0.008)
Edad ²	0.000 (0.000)	-0.000 (0.000)	0.000 (0.000)	-0.000 (0.000)
Educacion media	-0.007 (0.025)	0.105 (0.055)	-0.005 (0.027)	0.099 (0.049)
Educacion superior	-0.023 (0.025)	0.079 (0.057)	-0.023 (0.027)	0.074 (0.051)

Nota: la categoría de referencia para educación es Baja. Las columnas Probit reportan efectos marginales promedio. Errores estándar entre paréntesis. La variable dependiente es una medida binaria de propensión a consumir marihuana en los últimos 12 meses.

Los hallazgos del benchmark son consistentes con la literatura: *(i)* las mujeres reportan menor propensión (-0.065 en MCO; efecto marginal cercano a -0.064 en Probit); *(ii)* la edad entra con signo negativo dominante; *(iii)* el coeficiente de $\log(\text{precio})$ es positivo en la submuestra, pero la selección invalida una lectura causal limpia; *(iv)* la educación cambia entre muestras, reflejando la composición de la submuestra con precio.

6 Modelos de Machine Learning

6.1 Especificación de los modelos

Para una comparación limpia, los modelos de *machine learning* se entrenan sobre exactamente el mismo conjunto de variables del benchmark sin precio (edad, edad², sexo, educación agrupada), bajo la misma partición `train/test` 80/20 estratificada (`random_state=42`).

- **Random Forest**: 300 árboles, `max_depth=7`, `min_samples_leaf=10`. *Bagging* robusto a *outliers*.
- **XGBoost**: 300 árboles, `max_depth=5`, `learning_rate=0.05`, `subsample=0.8`, ponderando por la prevalencia.
- **Gradient Boosting (sklearn)**: 300 árboles, `max_depth=3`, `learning_rate=0.05`, `subsample=0.8`, `min_samples_leaf=15`.

6.2 Tabla comparativa de desempeño

Table 6: Comparación de modelos — métricas sobre conjunto de prueba y CV 5-fold

Modelo	Accuracy	AUC-ROC	F1	CV AUC (5-fold)
MCO (LPM)	0.6608	0.7232	0.5982	0.6728
Probit	0.6608	0.7228	0.5982	0.6728
Random Forest	0.6533	0.7063	0.5763	0.6674
XGBoost	0.6432	0.7001	0.5610	0.6614
Gradient Boosting	0.6545	0.7093	0.5736	0.6716




Figure 1: Comparación visual del desempeño en prueba: benchmark vs *machine learning*.




Figure 2: Curvas ROC para los cinco modelos sobre el conjunto de prueba.

Hallazgo no obvio. Con los hiperparámetros por defecto, ninguno de los tres modelos de *machine learning* supera al benchmark econométrico. Esto sugiere que con sólo cuatro *features* la relación es aproximadamente lineal y el MCO paga un costo mínimo de sesgo. La pregunta clave entonces es si esa diferencia desaparece tras un *tuning* disciplinado.

7 Validación, robustez y selección del modelo final

7.1 Validación cruzada de 10 pliegues




Figure 3: Distribución de AUC-ROC en validación cruzada de 10 pliegues: Random Forest y Gradient Boosting frente al CV de MCO (línea punteada de referencia).

La validación cruzada de 10 pliegues confirma estabilidad: las medianas de Random Forest (0.6674) y Gradient Boosting (0.6716) son muy cercanas al CV del benchmark MCO (0.6728), pero con dispersión que se solapa.

7.2 Curvas de aprendizaje




Figure 4: Curvas de aprendizaje (*train vs. validation*) para Random Forest y Gradient Boosting.

Las curvas muestran convergencia entre *train* y *validation* en Gradient Boosting (brecha menor que en Random Forest), confirmando que el GBM controla mejor la varianza con esta configuración.

7.3 Búsqueda de hiperparámetros

Se ejecutó `RandomizedSearchCV` sobre Gradient Boosting con 60 combinaciones aleatorias y CV estratificada de 5 pliegues (300 ajustes totales). El espacio explorado incluyó `n_estimators`, `max_depth`, `learning_rate`, `subsample`, `min_samples_leaf` y `max_features`. La mejor configuración encontrada fue:

Hiperparámetro	Valor óptimo
<code>n_estimators</code>	157
<code>max_depth</code>	2
<code>learning_rate</code>	0.0422
<code>subsample</code>	0.972
<code>min_samples_leaf</code>	26
<code>max_features</code>	log2

Table 7: Hiperparámetros óptimos del Gradient Boosting Machine (GBM) tuneado.

7.4 Selección razonada del modelo final

Métrica	GBM base	GBM tuneado
AUC-ROC (test)	0.7093	0.7278
Accuracy (test)	0.6545	0.6621
F1-Score (test)	0.5736	0.6129
CV AUC (10-fold)	0.6716	0.6756

Table 8: Mejora del GBM tras el *tuning* de hiperparámetros.




Figure 5: Curva ROC del GBM tuneado, comparada con el benchmark MCO.

Decisión. Se selecciona el **Gradient Boosting tuneado** como modelo final. Argumentos: *(i)* mayor AUC-ROC en prueba (0.7278 vs 0.7232 del benchmark); *(ii)* mayor F1-Score (0.6129 vs 0.5982); *(iii)* brecha train-validation menor que Random Forest y XGBoost; *(iv)* hiperparámetros conservadores (árboles poco profundos, regularización fuerte) que reducen el riesgo de sobreajuste con n moderado.

7.5 Análisis de robustez con Y alternativa estricta

Atendiendo la discrepancia documentada en la Sección 4.3, se reentrena el GBM tuneado con $Y_{\text{alt}} = \mathbb{I}\{K_03 = 1\}$ y se comparan métricas:

Table 9: Robustez del GBM tuneado bajo definición alternativa estricta de la variable objetivo.

Métrica	Y original (consumo_12m)	Y estricta (K_03=1)	Δ
AUC-ROC (test)	0.7182	0.6870	-0.0312
Accuracy (test)	0.6445	0.7023	+0.0578
F1 (test)	0.5974	0.3050	-0.2925
CV AUC-10fold (mean)	0.6685	0.6951	+0.0267
CV AUC-10fold (std)	0.0354	0.0303	-0.0051

Interpretación. La CV AUC-10fold incluso *mejora* con la Y estricta (+0.0267), señal de que cuando la operacionalización de la variable es más limpia, la generalización del

modelo aumenta. La AUC-ROC en prueba cae moderadamente (-0.031) pero permanece sobre el azar. La caída de F1 (-0.29) se explica por la menor prevalencia (0.31 vs 0.43): con un umbral fijo de 0.5, muchos positivos se pierden; la discriminación (AUC) sigue alta. *Las relaciones estructurales detectadas por el modelo son robustas a la elección de la operacionalización.*

8 Interpretabilidad con valores SHAP

8.1 Metodología

Los valores SHAP [2] descomponen cada predicción del modelo como una suma de contribuciones por variable, con la propiedad de aditividad: $f(x_i) = \phi_0 + \sum_j \phi_{ij}$. La importancia global se aproxima como el promedio del valor absoluto de las contribuciones, $\text{Imp}_j = \mathbb{E}[|\phi_j|]$.

8.2 Importancia global




Figure 6: Importancia media absoluta de las variables según SHAP (GBM tuneado, conjunto de prueba).

Table 10: Importancia media absoluta de las variables según valores SHAP.

Variable	Importancia SHAP	Participación
edad	0.3013	41.4%
edad_cuadrado	0.2552	35.1%
sexo_label_Mujer	0.1116	15.3%
educacion_grupo_Media	0.0348	4.8%
educacion_grupo_Superior	0.0247	3.4%

La edad y su término cuadrático concentran **aproximadamente 77%** de la importancia absoluta. El sexo aporta 15% adicional y la educación, cerca de 8% entre las dos categorías. Esta concentración tiene una implicación metodológica directa: con sólo cuatro *features*, el modelo no puede ir mucho más allá de un segmentador edad-sexo. La ganancia del *Gradient Boosting* sobre el benchmark proviene de capturar mejor la forma funcional de la edad (no monótona y no estrictamente cuadrática), no de descubrir patrones nuevos.

8.3 Lectura individual




Figure 7: SHAP *summary plot* — distribución de contribuciones por variable e individuo en el conjunto de prueba. Cada punto representa una persona; el color codifica el valor de la variable (rojo = alto, azul = bajo).




Figure 8: Dependencia parcial SHAP para la edad — relación no monótona capturada por el GBM.

El gráfico de dependencia confirma la forma funcional implícita: la contribución a la propensión es positiva en cohortes jóvenes y decae con la edad, con un patrón que el lineal aproxima sólo en promedio. Esto justifica empíricamente la ganancia predictiva del GBM.

9 Ética, sesgos y limitaciones

9.1 Sesgos del dato

Autoreporte y deseabilidad social. La encuesta captura comportamientos socialmente estigmatizados. Es bien documentado que el autoreporte de consumo subestima la prevalencia real, y que ese subreporte se correlaciona con la percepción de riesgo legal y social. Por construcción, el modelo aprende propensión a *reportar* consumo, no propensión a *consumir*.

Sesgo de selección por cobertura de precio. La submuestra con precio ($n \approx 755$) está fuertemente seleccionada hacia personas más expuestas al mercado. Por ello el benchmark con precio se reporta como exploratorio, y los modelos de ML se entrenan sobre la muestra amplia sin precio.

Sesgo de medición en la Y. La discrepancia entre `consumo_12m` y `K_03` (Sección 4.3) introduce ruido. La robustez (Sección 7.5) muestra que las conclusiones cualitativas se mantienen, pero un trabajo definitivo debería reconciliar la construcción de la variable.

9.2 Riesgos del uso del modelo

1. **Perfilado individual.** Con $AUC \approx 0.73$, las distribuciones de propensión por grupo se solapan sustancialmente. Usar el modelo para decisiones sobre personas (perfilado policial, decisiones laborales, vigilancia escolar) sería un mal uso: el costo social del falso positivo es severo dado el estigma asociado.
2. **Asociaciones, no causalidad.** Los SHAP muestran asociaciones. Que el modelo asigne mayor probabilidad a hombres jóvenes no implica causalidad; la edad y el sexo están correlacionados con factores no observados (red social, exposición, entorno).
3. **Estigma reforzado.** Publicar mapas o perfiles de consumo puede reforzar estereotipos. La comunicación pública debe privilegiar lecturas agregadas sobre lecturas individuales.

9.3 Uso responsable propuesto

El modelo se propone como herramienta **agregada** para: *(i)* estimar tamaños de mercado bajo escenarios regulatorios; *(ii)* apoyar el diseño tributario simulando bases de contribuyentes por estratos amplios; *(iii)* priorizar segmentos para política preventiva. No se recomienda para decisiones individuales ni para focalización geográfica fina sin análisis adicional de equidad.

10 Implicaciones económicas y de política pública

Tamaño y demografía del mercado. El GBM tuneado permite clasificar la población encuestada en grupos de mayor o menor propensión, insumo para una proyección poblacional con estructura etaria del DANE. La concentración en cohortes 18–35 años sugiere un mercado potencial relativamente acotado en términos de personas, pero con probable alta frecuencia de consumo en el segmento activo.

Diseño tributario. Si Colombia avanzara hacia un marco regulado, la base de contribuyentes (vía IVA u otro impuesto al consumo) estaría concentrada en cohortes jóvenes-masculinas. La elasticidad-precio probablemente es elevada en ese segmento, lo cual exige cautela: un impuesto demasiado alto desplazaría la demanda al mercado ilegal, anulando el efecto recaudatorio. Una proyección de recaudo creíble requiere acoplar este modelo

de propensión con una elasticidad-precio estimada limpiamente, algo que la submuestra disponible no permite.

Política preventiva. Las cohortes 18–25 años son las de mayor propensión observada. Esto justifica focalizar campañas de información y prevención en ese rango y diseñar mecanismos diferenciados por sexo.

Trabajo futuro. Las líneas más prometedoras son: *(i)* expandir el *feature set* con variables de entorno (geografía, red social, ingreso del hogar); *(ii)* resolver la construcción de la variable objetivo a partir de K_03 directo; *(iii)* estimar elasticidad-precio con un diseño que corrija el sesgo de selección de la submuestra con precio.

11 Reproducibilidad

El proyecto está organizado para que cualquier análisis pueda repetirse de forma transparente:

- **Pipeline CLI:** `python -m cannabis_tax.cli pipeline` ejecuta limpieza, validación y construcción de la base modeladora.
- **Notebook 01:** `notebooks/01_eda_y_mco_propension.ipynb` — EDA y benchmark.
- **Notebook 03:** `notebooks/03_modelos_ml.ipynb` — entrenamiento inicial de RF/XGBoost/GBM.
- **Notebook 04:** `notebooks/04_pca.ipynb` — exploración PCA complementaria.
- **Notebook 05:** `notebooks/05_validacion_semanas10_12.ipynb` — validación cruzada, búsqueda de hiperparámetros, selección del modelo final.
- **Notebook 06:** `notebooks/06_interpretabilidad_etica.ipynb` — SHAP, robustez con Y alternativa y discusión ética.
- **Tests:** `make test` corre la suite de pruebas unitarias del paquete.

Todas las tablas y figuras del paper se exportan automáticamente desde el código y residen en `reports/tables/` y `reports/figures/`.

12 Conclusiones

Este trabajo cubrió el ciclo completo CRISP-DM aplicado a la propensión al consumo de marihuana en Colombia: desde la construcción de la base hasta la interpretabilidad y la discusión ética. Las conclusiones principales son cuatro.

Primera. El benchmark econométrico (MCO y Probit) ofrece un punto de partida sólido y, con sólo cuatro regresores demográficos, alcanza una AUC-ROC de 0.7232 en prueba. Esto debe ser el punto de comparación para cualquier modelo más complejo en este dataset.

Segunda. El *Gradient Boosting* con hiperparámetros por defecto *no supera* al benchmark. La ganancia del *machine learning* sólo se materializa después de un *tuning* disciplinado: el GBM tuneado alcanza AUC-ROC 0.7278 y F1 0.6129, superando al benchmark de manera modesta pero consistente. La lección académica es que la flexibilidad funcional sin regularización adecuada introduce varianza que opaca cualquier ganancia de sesgo.

Tercera. La interpretabilidad SHAP muestra que la edad y su término cuadrático concentran cerca del 77% de la importancia absoluta del modelo, con el sexo aportando un 15% adicional. Es un modelo *honestamente delgado*: con cuatro *features*, el techo de información está cerca. La línea natural de mejora es ampliar el *feature set* con variables de entorno.

Cuarta. El análisis de robustez con $Y_{\text{alt}} = \mathbb{1}\{K_03 = 1\}$ confirma que las relaciones estructurales no dependen de la operacionalización elegida para la variable objetivo, pero la discrepancia documental entre `consumo_12m` y `K_03` debe quedar declarada como limitación seria del trabajo y como prioridad de resolución para una eventual fase posterior.

En términos de uso, el modelo se propone como insumo agregado para análisis de mercado y diseño tributario, no para decisiones individuales. Esa frontera no es accesorio: es parte sustantiva de lo que significa hacer *ciencia de datos* con responsabilidad en un dominio sensible.

References

- [1] Becker, G. & Murphy, K. (1988). A Theory of Rational Addiction. *Journal of Political Economy*, 96(4), 675–700.
- [2] Lundberg, S. M. & Lee, S.-I. (2017). A Unified Approach to Interpreting Model Predictions. *NeurIPS 2017*.
- [3] DANE. Encuesta Nacional de Consumo de Sustancias Psicoactivas.
- [4] Friedman, J. H. (2001). Greedy function approximation: A gradient boosting machine. *Annals of Statistics*, 29(5), 1189–1232.
- [5] Hastie, T., Tibshirani, R. & Friedman, J. (2009). *The Elements of Statistical Learning* (2nd ed.). Springer.