

Propensión al Consumo de Marihuana en Colombia

Benchmark Econométrico, Modelos de *Machine Learning* e Interpretabilidad SHAP

Santiago Tupaz, Moisés Quintero, Vanessa Rodrigues

Universidad EAFIT, Programa de Economía

Profesora Supervisora: Paula María Almonacid Hurtado

12 de mayo de 2026

Contexto y motivación

- **Tendencia global:** más de 40 países han legalizado el cannabis en alguna forma.
- **Colombia:** el debate sobre regulación incorpora hoy preguntas económicas concretas (tamaño de mercado, base tributaria, política preventiva).
- **Pregunta previa:** antes de cualquier simulación fiscal, hay que caracterizar empíricamente **quién consume** y **con qué propensión**.
- **Insumo natural:** la Encuesta Nacional de Consumo de Sustancias Psicoactivas (ENCSPA).

Brecha que aborda este trabajo

- Pocos modelos comparan rigurosamente **benchmark econométrico vs. *machine learning*** en este dominio para Colombia.
- Escasa discusión estructurada de **ética y sesgos** en estudios de consumo de drogas con datos de encuesta.
- Necesidad de **interpretabilidad** (no sólo precisión) cuando el modelo se usa para política pública.

Nuestra contribución: pipeline reproducible + comparación honesta + interpretabilidad SHAP + frontera ética explícita.

¿Por qué importa?

Dimensión económica:

- Tamaño potencial del mercado
- Base tributaria si se legaliza
- Elasticidad-precio del segmento

Dimensión social:

- Focalización de prevención
- Reducción del estigma vía datos
- Uso responsable de IA en política

Pregunta central

¿Qué factores sociodemográficos observables se asocian con la probabilidad de reportar consumo de marihuana en los últimos doce meses en Colombia, y cuánto mejora la predicción al pasar de un benchmark econométrico a modelos de *machine learning*?

Componentes:

- 1 **Descriptivo-causal:** signo, magnitud y estabilidad de los predictores.
- 2 **Predictivo:** ganancia del ML sobre el lineal manteniendo el mismo *feature set*.

Variable objetivo y unidad de análisis

Variable dependiente: $\text{propension_12m} \in \{0, 1\}$ — reportó consumo de marihuana en los últimos 12 meses (base limpia, derivada de K_03 + señales auxiliares).

Unidad de análisis: individuo encuestado (ENCSPA).

Tipo de problema: clasificación binaria.

Nota crítica: la construcción de propension_12m difiere de K_03 *raw* en 898 casos. Se documenta como limitación y se atiende con un análisis de robustez (Y estricta = $K_03=1$).

Objetivos

General: construir un pipeline reproducible que compare benchmark econométrico y *machine learning* para la propensión al consumo, con interpretabilidad y reflexión ética explícitas.

Específicos:

- 1 Integrar y limpiar la base de la ENCSPA con módulos sociodemográficos.
- 2 Estimar benchmark MCO/Probit y modelos ML comparables.
- 3 Validar con CV-10 y tunear hiperparámetros del modelo final.
- 4 Interpretar con valores SHAP y verificar robustez.
- 5 Discutir sesgos, ética y usos legítimos del modelo.

Base integrada

- $n = 3\,982$ individuos
- Base limpia de consumo (ENCSPA)
- Módulo personas (sexo, edad)
- Módulo d2 (educación)

Cobertura clave

- Edad, sexo, educación: $\sim 100\%$
- consumo_12m: 1 719 unos
- Precio: 823 (submuestra exploratoria)

Decisión: ML sobre la muestra amplia sin precio ($n = 3\,980$).

Pipeline reproducible

- 1 `python -m cannabis_tax.cli pipeline`: limpieza, validación y construcción de la base modeladora.
- 2 Notebook 01: EDA + benchmark MCO/Probit.
- 3 Notebook 03: entrenamiento RF, XGBoost, GBM.
- 4 Notebook 05: CV-10, búsqueda de hiperparámetros, selección del modelo final.
- 5 Notebook 06: SHAP + robustez + ética.

Tests: `make test` corre la suite unitaria.

MCO (LPM):

$$y_i = \beta_0 + \beta_2 edad_i + \beta_3 edad_i^2 + \beta_4 mujer_i + \beta_5 educacion_i + u_i$$

con errores HC1.

Probit:

$$\Pr(y_i = 1 \mid X_i) = \Phi(\alpha_0 + \alpha_2 edad_i + \alpha_3 edad_i^2 + \alpha_4 mujer_i + \alpha_5 educacion_i)$$

con efectos marginales promedio.

Roles: referencia interpretable y punto de comparación.

Modelos de Machine Learning

- **Random Forest:** *bagging*, 300 árboles, `max_depth=7`.
- **XGBoost:** *boosting* secuencial, ponderado por prevalencia.
- **Gradient Boosting (sklearn):** *boosting* conservador, `max_depth=3`.

Reglas de comparación:

- Mismo *feature set* que el benchmark (edad, edad^2 , sexo, educación).
- Mismo train/test split estratificado (`random_state=42`).
- Métricas: Accuracy, AUC-ROC, F1, CV AUC (5 y 10 folds).

Validación y selección

- ① **CV-10**: estabilidad y solapamiento entre modelos.
- ② **Curvas de aprendizaje**: control de *overfitting*.
- ③ **RandomizedSearchCV**: 60 combinaciones $\times$ 5 folds sobre el GBM.
- ④ **Criterios**: AUC-ROC, F1, brecha train-validation, plausibilidad económica.

No se evalúa sólo precisión: la argumentación pesa tanto como el número.


Tabla comparativa — benchmark vs. ML

Modelo	Accuracy	AUC-ROC	F1	CV AUC (5-fold)
MCO (LPM)	0.6608	0.7232	0.5982	0.6728
Probit	0.6608	0.7228	0.5982	0.6728
Random Forest	0.6533	0.7063	0.5763	0.6674
XGBoost	0.6432	0.7001	0.5610	0.6614
Gradient Boosting	0.6545	0.7093	0.5736	0.6716
GBM tuneado	0.6621	0.7278	0.6129	0.6756


Hallazgo no obvio: con hiperparámetros por defecto el ML *no* supera al benchmark. La ganancia aparece tras un *tuning* disciplinado.

Comparación visual benchmark vs. ML

Comparación de desempeño — Benchmark vs ML



Validación cruzada de 10 pliegues



Distribución de AUC-ROC en CV-10. Solapamiento sustancial con el CV de MCO (0.673) antes del tuning.

Búsqueda de hiperparámetros (GBM)


Espacio: RandomizedSearchCV, 60 combinaciones $\times$ 5 folds = 300 ajustes.

Hiperparámetros óptimos:

n_estimators	157
max_depth	2
learning_rate	0.0422
subsample	0.972
min_samples_leaf	26
max_features	log2

Patrón: árboles muy poco profundos + regularización fuerte $\Rightarrow$ menor varianza.

Modelo final — GBM tuneado



AUC-ROC test = **0.7278** | F1 = **0.6129** | CV-10 AUC = 0.6756

¿Por qué SHAP?

Problema: el GBM es una caja gris. Sin interpretabilidad, no es útil para política pública.


SHAP (Lundberg & Lee, 2017): descompone cada predicción como suma de contribuciones por variable.

Propiedad clave: aditividad

$$f(\mathbf{x}_i) = \phi_0 + \sum_j \phi_{ij}$$


La importancia global es $\text{Imp}_j = \mathbb{E}[|\phi_j|]$.

Importancia SHAP — global




edad + **edad²** concentran $\sim 77\%$ de la importancia. Sexo: 15%. Educación: 8%.

SHAP summary — distribución individual



Dependencia parcial — edad



Relación no monótona: positiva en jóvenes, decae con la edad. Por qué gana el GBM: captura mejor esta forma funcional que el lineal.

Robustez — Y alternativa estricta

Motivación: la auditoría detectó que consumo_12m difiere de K_03 en 898 casos.

Test: reentrenar el GBM tuneado con $Y_{\text{alt}} = \mathbb{I}\{K_03 = 1\}$.

Métrica	Y original	Y estricta	Δ
AUC-ROC (test)	0.7182	0.6870	-0.031
CV AUC-10fold (mean)	0.6685	0.6951	+0.027

Conclusión: las relaciones estructurales se mantienen; la discrepancia no domina el resultado.

Sesgos del dato

- **Autoreporte y deseabilidad social:** el modelo aprende propensión a *reportar*, no a *consumir*. Subreporte correlacionado con percepción de riesgo legal.
- **Sesgo de selección por precio:** la submuestra con precio ($n \approx 755$) está sesgada hacia personas más expuestas al mercado.
- **Sesgo de medición en Y:** discrepancia documentada consumo_12m vs K_03. Mitigada con análisis de robustez.

Riesgos del uso del modelo

- ❶ **Perfilado individual:** $AUC \approx 0.73$ implica solapamiento alto entre grupos. *No usar* para decisiones sobre personas (policial, laboral, escolar).
- ❷ **Asociaciones $\neq$ causalidad:** edad y sexo correlacionan con factores no observados (red social, entorno).
- ❸ **Estigma reforzado:** mapas y perfiles públicos refuerzan estereotipos. Privilegiar lecturas agregadas.

Uso responsable propuesto

Sí (uso agregado):

- Estimar tamaño de mercado bajo escenarios regulatorios.
- Diseño tributario simulando bases de contribuyentes por estratos amplios.
- Priorizar segmentos para política preventiva.

No (uso individual):

- Decisiones sobre personas específicas.
- Focalización geográfica fina sin análisis de equidad.
- Predicciones puntuales sin intervalos de incertidumbre.

Diseño tributario:

- Base concentrada en cohortes jóvenes-masculinas.
- Elasticidad-precio probablemente alta $\Rightarrow$ impuesto excesivo desplaza al mercado ilegal.
- Recauda creíble requiere acoplar este modelo con una elasticidad estimada limpia.

Política preventiva:

- Focalizar en 18–25 años, diferenciada por sexo.
- Aprovechar la sensibilidad de la cohorte a intervenciones tempranas.

Hallazgos clave

- 1 El benchmark MCO/Probit alcanza $AUC-ROC = 0.7232$. Es un piso difícil de superar con sólo 4 *features*.
- 2 Los modelos ML por defecto *no* superan al benchmark.
- 3 El **GBM tuneado** sí lo hace: $AUC = 0.7278$, $F1 = 0.6129$.
- 4 SHAP: $edad + edad^2 \approx 77\%$ de la importancia. Modelo *honestamente delgado*.
- 5 Robustez Y alternativa: relaciones estructurales estables.

Lecciones metodológicas

- La flexibilidad sin regularización introduce varianza que opaca la ganancia de sesgo.
- El *tuning* disciplinado importa más que el algoritmo en datos chicos.
- La interpretabilidad no es opcional: define qué tan utilizable es el modelo para política.
- Documentar limitaciones (Y discrepante, submuestra con precio) es parte del trabajo, no un anexo.

Próximos pasos

- Reconciliar la construcción de consumo_12m con K_03 directo.
- Ampliar el *feature set* con variables de entorno (geografía, red social, ingreso del hogar).
- Estimar elasticidad-precio con un diseño que corrija el sesgo de selección.
- Acoplar el modelo de propensión con proyecciones poblacionales del DANE para simulación tributaria.

Preguntas y discusión

Tupaz, Quintero, Rodrigues — Universidad EAFIT
Profesora supervisora: Paula María Almonacid Hurtado